# 量化投资交易

主讲人：黎新平

北京大学金融工程实验室

# 第四章

# 因子模型

# 01

# CAPM模型回顾

## 1. CAPM模型

- 因子模型可以追溯到最早的CAPM模型，该模型由夏普（Sharpe）在1964年提出， 是在马可维茨（Markowitz）组合优化理论框架下的市场均衡模型。

- CAPM模型的主要思想：在均衡的市场中，只有证券或证券组合的系统性风险才能获得收益补偿，其非系统性风险将得不到收益补偿。非系统性风险可以被投资者进行充分分散化投资消除。

- 夏普于1964年进一步证明，在一定条件下，当市场达到均衡时，相切的风险资产组合也就是整个市场组合M。所有有效组合都可视为无风险证券F与市场组合M的在组合。CAPM模型通过资本市场线揭示有效组合的收益和风险之间的均衡关系，这种关系可以用资本市场线方程（CML）来描述：

$$E(r_p) = r_F + \frac{E(r_M) - r_F}{\sigma_M}\sigma_P$$

式中：

$E(r_p)$、 $\sigma_P$ ，有效组合P的期望收益率和标准差。

$E(r_M)$、 $\sigma_M$ ，市场组合M的期望收益率和标准差。

$r_F$ ，无风险证券收益率

# 1. CAPM模型

$$E(r_p) = r_F + \frac{E(r_M) - r_F}{\sigma_M}\sigma_P$$

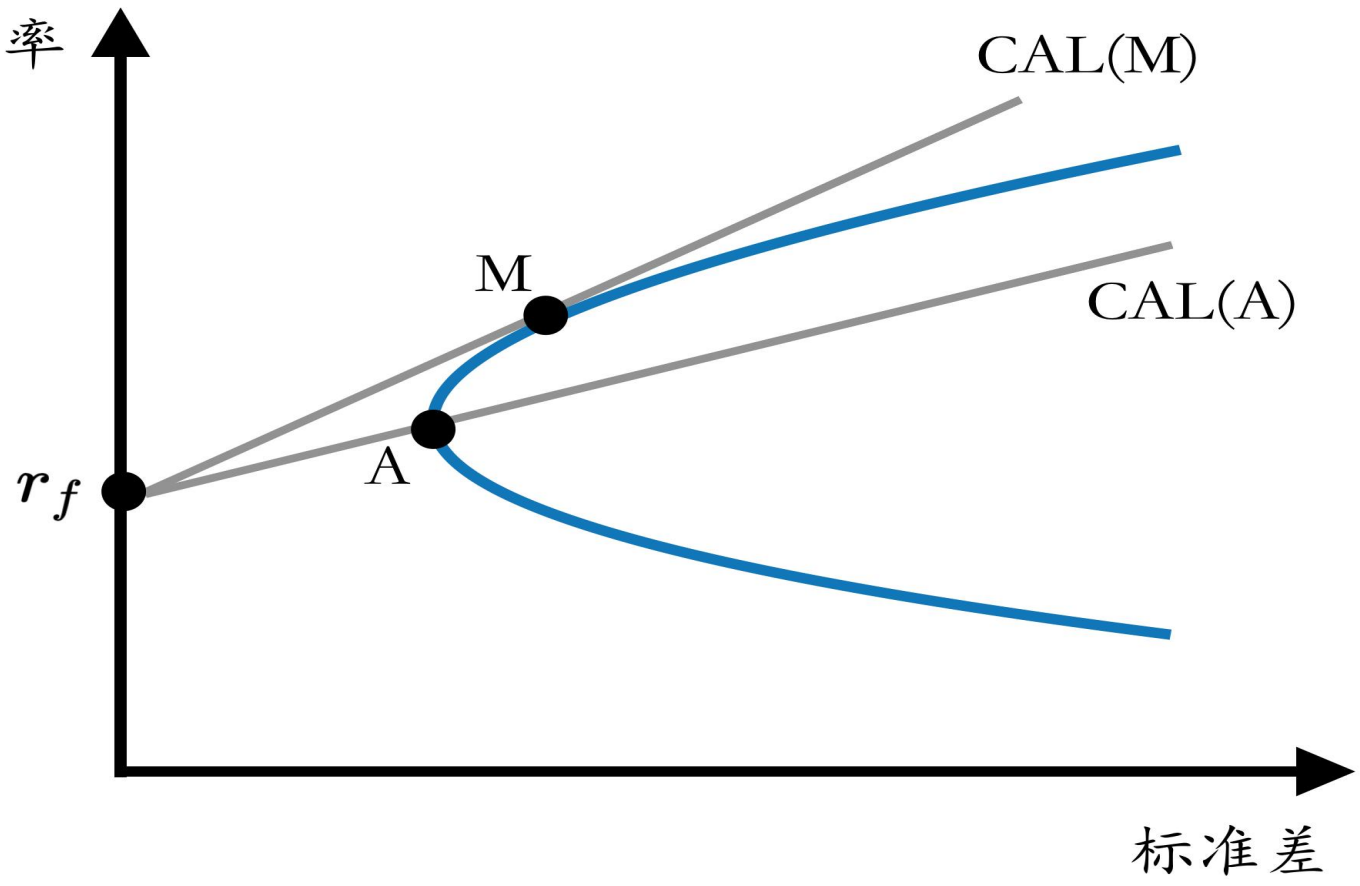

## 1. CAPM模型

从这出发，夏普给出了每一个风险资产的预期收益应满足以下条件：

$$\mathrm{E}[r_i] - E[r_f] = \beta_i^m (r_m - r_f)$$

其中， $\mathrm{E}[r_i]$是第i种资产的收益率， $r_f$是无风险资产的收益率， $r_m$是市场组合的收益率，而$\beta_i^m$则是第i种资产相对于市场的贝塔系数。它所揭示的是第i种资产的系统性风险。 $\beta_i^m$的计算可以由下式得到：

$$\beta_i^m = \frac{cov(R_i, R_m)}{\sigma^2(R_m)}$$

CAPM证明：

（1）推导资本配置线(CAL)，得到所有组合能得到的最大夏普比率为：

$$\frac{E(r_M) - r_F}{\sigma_M}$$

（2）假设构建任一投资组合 $E(r_p) = \mathrm{w} * E(r_i) + (1 - w) * E(r_M)$，该投资组合的方差为

$$\sigma_p = \sqrt{w^2 * \sigma_i^2 + （1 - w)^2 * \sigma_M^2 + 2w(1 - w)\sigma_{iM}}$$

（3）该投资组合的在w=0处的斜率为：

$$\frac{dE(r_p)}{d\sigma_p} = \frac{dE(r_p)/dw}{d\sigma_p/dw} = \frac{E(r_i) - E(r_M)}{\frac{1}{2\sigma_p}(2w\sigma_i^2 - 2(1 - w)\sigma_M^2 + 2\sigma_{iM} - 4w\sigma_{iM})}\Big|_{w=0} = \frac{E(r_i) - E(r_M)}{\sigma_{iM} - \sigma_M^2}\sigma_M$$

$$\frac{E(r_i) - E(r_M)}{\sigma_{iM} - \sigma_M^2}\sigma_M = \frac{E(r_M) - r_F}{\sigma_M}$$

CAPM证明：

*由前面推导我们有：*

$$\frac{E(r_i)-E(r_M)}{\sigma_{iM}-\sigma_M^2}\sigma_M=\frac{E(r_M)-\ r_F}{\sigma_M}$$

$$(E(r_i)-E(r_M))\sigma_M^2=(E(r_M)-\ r_F)(\sigma_{iM}-\sigma_M^2)$$

$$E(r_i)\sigma_M^2-E(r_M)\sigma_M^2=E(r_M)\sigma_{iM}-\ r_F\sigma_{iM}-E(r_M)\sigma_M^2+\ r_F\sigma_M^2$$

$$E(r_i)\sigma_M^2-r_F\sigma_M^2=E(r_M)\sigma_{iM}-\ r_F\sigma_{iM}$$

$$\mathrm{E}[r_i]-E\left[r_f\right]=\frac{\sigma_{iM}}{\sigma_M^2}(E(r_M)-r_f)=\beta_i^m(E(r_M)-r_f)$$

CAPM的局限性：

假设条件：

- 投资者均为理性、风险厌恶且追求效用最大化；
- 所有投资者具有同质预期；
- 投资期限单一且相同；
- 市场完全有效、无交易成本、税收及信息成本；
- 存在无风险资产，且所有投资者可按同一无风险利率自由借贷；
- 资产无限可分，投资规模不受限制；

如何检验？ α=0是否显著

先用时序数据回归得到βi，再对不同公司i做横截面回归，得到市场超额收益率。

**CAPM检验的核心要点：**

检验方法：
（1）个股的超额收益率，即股票收益率减去无风险利率，对市场组合的超额收益率进行OLS回归，截距项是否为零；

（2）采用Fama-MacBeth两步回归法（Fama, MacBeth, 1973)
第一步：时间序列回归，估计投资组合的$\beta$。
第二步：横截面回归，利用$\beta$解释不同组合的平均收益率。

经典实证结论：
- 模型有效性：在（1）的检验中，截距项往往并不为零，模型解释力不充分；
- $\beta$的有效性：证券收益与$\beta$之间确实存在正向线性关系。
- 斜率偏差：实证得出的零贝塔收益率（截距）高于无风险利率，且斜率小于市场风险溢价，即模型低估了低风险资产的收益，高估了高风险资产的收益。
- $\beta$不是唯一因素：研究表明，除了$\beta$之外，如公司规模（Size）、账面市值比（B/M）等因素也对股票预期收益有显著的解释能力，这导致了后续三因子模型等的发展。

检验的局限性（Roll's Critique）：罗尔（Roll）指出，CAPM不可检验，因为我们无法找到真正的“市场组合”，所有检验实际上是在检验所使用的代理指数（如S&P 500）是否有效，而非CAPM本身。

（2）APT模型

在CAMP的模型基础之上，罗斯（Ross）于1976年提出了无风险套利模型（APT）。在该模型中，第i种资产的收益由下面的线性公式决定：

$$R_i = \alpha_i + \sum_{j=1}^{N} \beta_j^i F_j + \epsilon_i$$

其中，$\alpha_i$是常数项，$F_j$是第j项因子，$\beta_j^i$而则是第i种资产相对第j项因子的反应系数，$\epsilon_i$ 则是第i种资产残余项。满足以下条件：

1. $E(\epsilon_i) = 0$;
2. $cov(\epsilon_i,\ \epsilon_j) = 0\ for\ i \neq j$;
3. $cov(\epsilon_i, F_j) = 0$;

定义 $E\left(r_{F_j}\right) - r_f$为因子$F_j$的风险溢价，则

$$E(r_i) = r_f + \beta_1^i (E(r_{F_1}) - r_f) + \beta_2^i (E(r_{F_2}) - r_f) + \cdots + \beta_N^i (E(r_{F_N}) - r_f)$$

（2）APT模型的证明：

$$R_i = \alpha_i + \sum_{j=1}^{N} \beta_j^i F_j + \epsilon_i$$

$$R = \alpha + \beta F + \epsilon$$

无风险：$w'\beta = 0$ --> $w \perp \beta$
无成本：$w'I = 0$ --> $w \perp I$
因而， $w \perp span(\beta, I)$

对于任意无风险、无成本的投资组合w, 其期望收益为零，即$w'E(R) = 0$。因而有：$E(R)$*在* $span(\beta, I)$*张成空间内，因而*$\exists\lambda_0$、$\lambda_1$，

$$E(R) = \lambda_0 I + \lambda_1 \beta$$

（2）APT模型的证明：

$$E(R) = \lambda_0 I + \lambda_1 \beta$$

对于无风险资产$f$，$\beta_f = 0$, 因而：

$$E(R_f) = \lambda_0$$
$$\lambda_0 = R_f$$

单风险因子情形：

假设只存在一种风险因子$F_M$，且：$R_M = \alpha_M + F_M + \epsilon_M$，则有$\beta_M = 1$。因而

$$E(R_M) = R_f + \lambda_1$$
$$\lambda_1 = E(R_M) - R_f$$

代入可得：

$$E(R) = \lambda_0 I + \lambda_1 \beta = R_f + \beta(E(R_M) - R_f)$$

APT的局限性：

假设条件：

- 资产收益率服从多因子线性模型；
- 市场允许充分分散化投资；
- 不存在无风险套利机会（无套利原则）；
- 无交易成本、税收及信息成本；
- 投资者是风险规避型，追求效用最大化；
- 资本市场是完全竞争的；

But:

- *APT不要求投资者具有相同预期、也不依赖市场组合的存在——这使其比CAPM假设更宽松。*

# 02

# Fama-French三因子模型

## 2. Fama-French三因子模型

size and value in china

Fama和French 1993年指出可以建立一个三因子模型来解释股票回报率。

模型认为，一个投资组合(包括单个股票)的超额回报率可由它对三个因子的暴露来解释，这三个因子是：市场资产组合(Rm− Rf)、市值因子(SMB)、账面市值比因子(HML)。这个多因子均衡定价模型可以表示为：

$$E(R_{it}) - R_{ft} = \beta_i[E(R_{mt} - R_{ft})] + s_i E(SMB_t) + h_i E(HMI_t)$$

其中

- $R_{ft}$表示时间t的无风险收益率；
- $R_{mt}$表示时间t的市场收益率；
- $R_{it}$表示资产i在时间t的收益率；
- $E(R_{mt}) - R_{ft}$是市场风险溢价，
- $SMB_t$为时间t的市值(Size)因子的模拟组合收益率(Small minus Big)，
- $HMI_t$为时间t的账面市值比(book-to-market)因子的模拟组合收益率(High minus Low)。

## 2. Fama-French三因子模型

具体计算过程：

Size：以观测时间t的市场价值为依据，把样本股票分为两组：Big 和 Small

BM：以观测时间t可获取的上一个财报为依据，把样本股票分为三组：

- *Value:* *30%*
- *Neutral:* *40%*
- *Growth:* *30%*

依据上述Size和BM的划分，把样本股票分为六组：

- *BigValue, Small Value*
- *BigNeutral, Small Neutral*
- *BigGrowth, SmallGrowth*

*注：在Fama-French的计算中，*

- *t年6月根据NYSE上市股票Market Capitalization的中位数来区分Small与Big，因而Small事实上包含股票数远多于Big;*
- *同样应用NYSE上市股票B/M的30%，70%分位数来区分Low，Medium与High。*

## 2. Fama-French三因子模型

在Fama-French的三因子模型中，三个因子的具体计算如下：

SMB：三个小市值组合的平均收益减去三个大市值组合的平均收益

$$SMB = \frac{1}{3}(SmallValue + SmallNeutral + SmallGrowth) - \frac{1}{3}(BigValue + BigNeutral + BigGrowth)$$

HML：两个高价值组合平均收益减去两个成长组合平均收益

$$HML = \frac{1}{2}(Small\,Value + Big\,Value) - \frac{1}{2}(Small\,Growth + Big\,Growth)$$

$R_m - R_f$：市场组合的超额收益率

市场组合收益率$R_m$为在美国注册并在纽约证券交易所、美国证券交易所或纳斯达克上市的所有CRSP公司的市值加权收益

## 2. Fama-French三因子模型

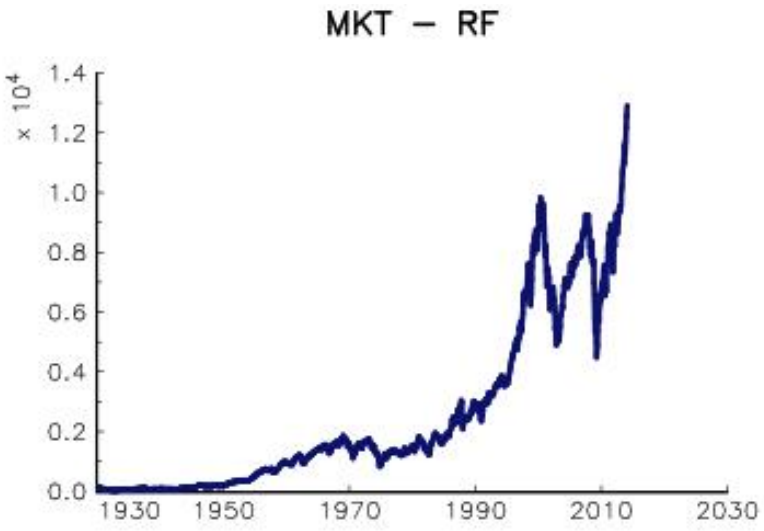

# 03

# 常用因子指标

## 3. 常用因子指标

在因子模型里，一个股票的收益率可能表示为：

$$\boldsymbol{r}_{N\times l} = \boldsymbol{X}_{N\times(P+Q+l)}\boldsymbol{f}_{(P+Q+l)\times l} + \boldsymbol{u}_{N\times l}$$

其中X为股票的因子暴露度，而f则为一单位因子暴露所能带来的因子收益率。因而在上述因子模型里面，一个股票的收益可以被分解成不同的因子暴露所带来的风险溢价。应用到量化投资策略中，就可以通过一个股票的因子暴露去预测或判断股票收益率的高低，因而去构建相关的量化策略。

## 3. 常用因子指标

从Fama-French的三因子开始，人们开始不断的开发新因子，试图从新因子里面发现市场的超额收益或不能被已有因子所解释的市场异象。而在一些金融机构里被跟踪和分析的因子，常常多达5000多个。

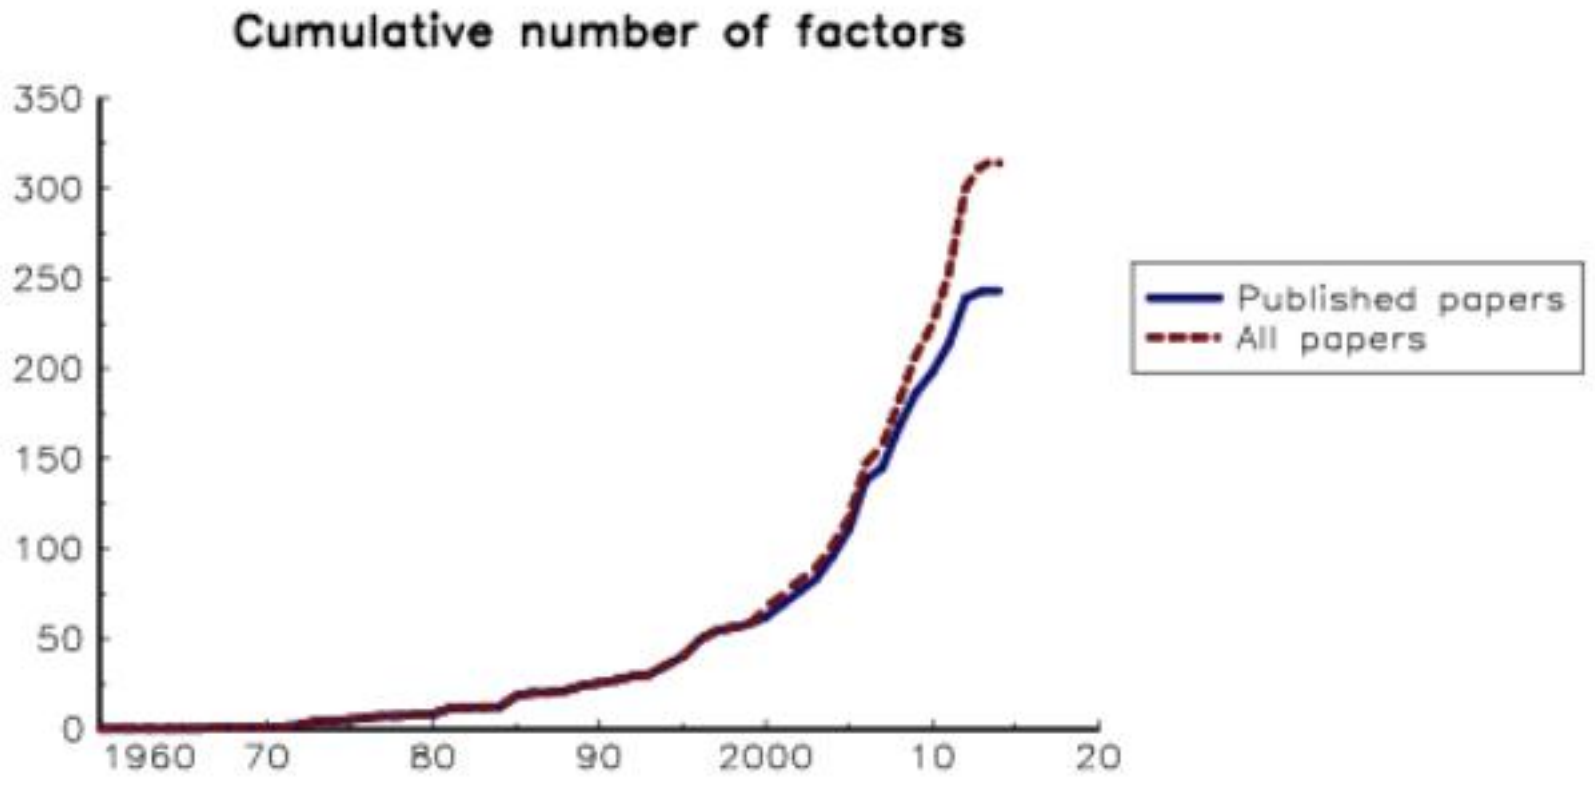


Harvey et al., 2014

## 3. 常用因子指标

以下是一些常用因子的举例：

- 价值类因子：如市盈率PE、市净率PB、市盈率增长比PEG等；
- 成长类因子：如主营收入增长率、净利润增长率、净资产增长率等；
- 规模类因子：如总市值、流通市值、总资产、公司价值等；
- 动量类因子：如一个月动量、三个月动量、换手率等；
- 技术类因子：如MACD、RSI、KDJ等；
- 质量类因子：如ROE、资产负债率、净利率、股息率等；

## 3. 常用因子指标：关于因子的一些观察

不同因子的重要性、有效性不尽相同。

因子具有时效性，受宏观环境 、均值修复等影响。

从美国市场看，一些因子有效性在逐渐下降。

同样因子，不同构建方式有时会产生非常不同的结果。

做多组合与多空组合表现不尽相同，多空组合不一定风险更低。

某些因子存在较大的尾巴风险， 比如趋势投资(momentum)。

因子有效性具有地域性，不同国家或地区因子表现并不一致。

因子间是相关的，且不一定是线性关系。

# 3. 常用因子指标：关于因子的一些观察

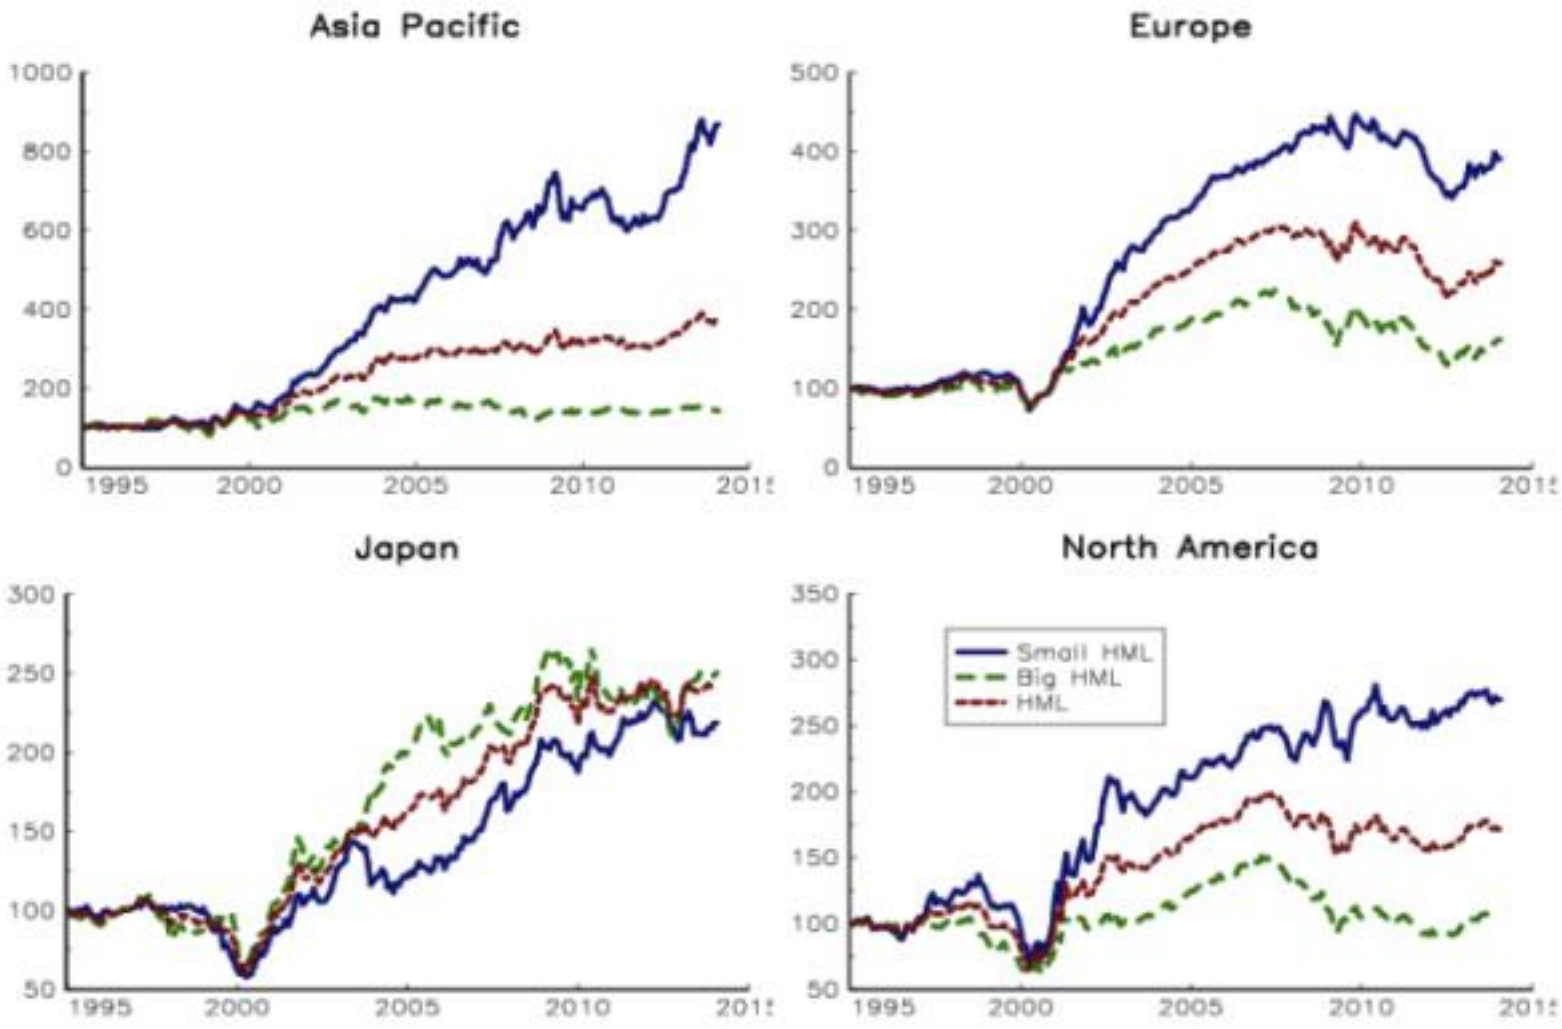

# 04

# 构造标准化因子

## 4. 构造标准化因子

要建立因子模型，首先要熟悉因子的构建过程。一个因子的计算需要经过以下的流程。

（1）获取数据；
- 行情数据、财务数据

（2）建立因子计算公式；
- 算子以及因子计算公式

（3）极值处理；
- 截断及异常值处理

（4）标准化处理；
- 标准化、排序

（5）中性化处理；
- 行业中性、市值中性以及正交

## 4. 构造标准化因子

（1）获取数据并建立因子的计算公式

- 对于每一个股票，获取该因子所涉及的价量数据或财务数据；

$$X_{i,t} = f(Z_{k,i,t}\ \ k = 1,2...K)$$

其中X是所要构造的因子，Z是所要用到的K个价量或财务指标，而f则是因子的具体计算公式。

- 在因子的自动构建流程中，通常会把计算公式f定义为不同的算子，然后通过调用相关的算子以完成公式的计算。

- 举例而言，比如要计算估值指标，市净率PB，那么会用到以下的公式：

$$PB = \frac{\text{公司总股数} * \text{股票最近收盘股价}}{\text{公司所有者权益}}$$

因而，首先需要去价格信息表获取股票最近一天的收盘价，去公司最近的报表中去找到公司最新总股数以及公司所有者权益。

定义算子

times(a,b)=a*b；　div(a,b)=a/b;

那么就可以得到

PB=div(times(公司总股数,股票最新收盘价),公司所有者权益);

（2）去极值

现实中真实数据所计算的因子值往往会存在非常多的异常值，而这些异常值在进行因子的分析或回归时会带来非常大的数值偏差，因而为了保证因子的稳定性以及结果的鲁棒性，通常在因子计算完之后需要进行因子的去极值处理。极值的去除有以下三种方式，分别为MAD、3σ、百分位法。

**MAD法：**又称为绝对值差中位数法（Median Absolute Deviation）。MAD处理的逻辑是：

- 第一步，找出所有因子的中位数$X_{median}$；
- 第二步，得到每个因子与中位数的绝对偏差值$|X_i - X_{median}|$；
- 第三步，得到绝对偏差值的中位数$MAD$；
- 最后，确定参数n，从而确定合理的范围为$[X_{median} - nMAD, X_{median} + nMAD]$，并针对超出合理范围的因子值做如下的调整：

$$X_i' = \begin{cases} X_{median} + nMAD & if\ \ X_i > X_{median} + nMAD \\ X_{median} - nMAD & if\ \ X_i < X_{median} - nMAD \\ X_{\mathrm{i}} & if\ \ X_{median} - nMAD < X_i < X_{median} + nMAD \end{cases}$$

（2）去极值

**3σ法：** 又称为标准差法。标准差本身可以体现因子的离散程度，是基于因子的平均值$X_{mean}$而定的。在极值处理过程中，可通过用$X_{mean} \pm n\sigma$来衡量因子与平均值的距离。

缺陷是σ和mean本身就容易受到极端值的影响

第一步，计算出因子的平均值与标准差$\sigma$，
第二步，确认参数 n（这里选定 n = 3），
第三步，确认因子值的合理范围为$[X_{mean} - n\sigma, X_{mean} + n\sigma]$，并对因子值作如下的调整：

$$X_i' = \begin{cases} X_{mean} + n\sigma & if\ \ X_i > X_{mean} + n\sigma \\ X_{mean} - n\sigma & if\ \ X_i < X_{mean} - n\sigma \\ X_{\mathrm{i}} & if\ \ X_{mean} - n\sigma < X_i < X_{mean} + n\sigma \end{cases}$$

**百分位法：** 计算的逻辑是将因子值进行升序的排序，对排位百分位高于 97.5%或排位百分位低于 2.5%的因子值，进行类似于 MAD 、3$\sigma$的方法进行调整。

3）标准化处理

标准化处理是一个去除量纲的方法，能够使得股票池中不同股票在每期的因子值的横截面数据都能有可比性，这里用到了 Z-score 的方法，将因子值的均值调整为 0，标准差调整为 1。

标准化处理基于原始数据的均值和标准差，处理的逻辑是因子值减去均值后，再除以标准差。公式如下：

$$X_i' = \frac{X_i - X_{mean}}{\sigma}$$

公式中， $X_{mean}$ 为因子的均值，σ为因子的标准差。

（4）中性化处理

在因子的使用中，为了更清晰的看到因子的表现，通常需进行中性化处理，把与因子无关的影响因素给排除掉。比如，因子构造过程中常常需时行行业中性化处理，其具体做法是在每个时间截面上用所有股票的数据做横截面回归方程：

$$Factor_i = \sum_{j=1}^{n} \beta_j \cdot Industry_{j,i} + \sigma_i$$

其中， $Factor_i$为股票i的 alpha 因子， $Industry_{j,i}$为行业虚拟变量，即如果股票i属于行业j则暴露度为 1，否则为 0，而且每个股票i仅属于一个行业。

上述回归方程的残差项作为原因子在中性化后的新因子。

# 05

# 量化故事：Fama及其学术成就

## 5. 量化故事：Fama及其学术成就

- 诺奖得主：2013年10月，因为对资产价格的实证分析，尤金·法玛与另一位芝加哥大学教授、芝加哥经济学派代表人物之一拉尔斯·彼得·汉森，以及罗伯特·希勒(Robert Shiller)获得2013年诺贝尔经济学奖 。

- 市场有效假说、多因子模型

- 学术生平

  - 1939年2月14日出生于美国马萨储塞州波士顿，意大利裔移民的第三代。
  - 1960年毕业于马萨储塞州塔夫茨大学（Tufts），主修法文，获得学士学位。
  - 1960－1963年在芝加哥大学商学院研究生院攻读MBA，1964年获得博士学位，其博士论文为“股票市场价格走势”。1966-1968芝加哥大学商学院研究生院 金融学副教授、1968-1993 芝加哥大学商学院研究生院 金融学教授。
  - 全球金融学论文引用率最高的学者。

- French网页：
  https://mba.tuck.dartmouth.edu/pages/faculty/ken.french/Data_Library/f-f_factors.html

# 课后作业

1. 认真学习了解Fama-French三因子模型；

2. 从2010年初到2020年底，计算沪市代码最小的10只股票与沪深300指数的一年滚动alpha；也即每个交易日t，取过去242个交易日，计算回归方程 $y = \alpha + \beta x + \varepsilon$，得到常数项alpha。（附加要求：避免使用循环）

3. 用python程序构造一个因子 (as of 2024年12月31日）；
要求：
（1）因子需通过财务指标或价格指标计算得到，最好是兼备财务和价格指标；
（2）可以复现米筐因子列表里的一个因子，但不能直接提取因子；
（3）说明为什么你认为该因子是值得研究的因子；
（4）提取数据对全市场股票计算该因子值；
（5）对因子进行去极值(MAD法)及标准化的处理；（暂不需要做中性化处理）
（6）画出该因子在全市场股票的分布图；

# 06

# Vibe Coding

1. CAPM模型

请计算平安银行相对于沪深300的beta值；[注意：get_price返回是multi-index的dataframe, index=(‘order_book_id’,’date’)]

请根据2024年底沪深300的成份股，计算每只股票在过去2年的beta值，并画出其分布图；

请对于股票列表['000300.XSHG','000001.XSHE', '600519.XSHG', '300039.XSHE']，计算每只股票在过去2年的滚动一年的beta值，要求不使用循环；画beta的时序图；

rolling计算个股和市场收益率的std，然后由公式计算β
怎么不使用循环算α？先用上面的方法算出β，然后用个股收益率均值 - β×市场收益率均值。这里面不会有ε，因为我们用的是均值。

**CAPM Testing：**

请构建代码，对CAPM模型进行检验，使用Fama-Macbeth方法：

（1）考察2025年年底的沪深300成份股；
（2）下载沪深300成份股以及沪深300指数2020年~2025年的日收益数据；
（3）以2020年~2024年数据计算每只股票的月度收益率的beta;
（4）以2025年全年收益率以及（3）的beta值验证CAPM模型；
（5）最后请画图展示CAPM模型的回归实证结果；

注意可能会出现的问题：

- 数据库返回的数据结构；
- 数据的对齐问题；

2. 因子构建

对于股票列表['000001.XSHE', '600519.XSHG', '300039.XSHE']，请给出PB的计算公式，并根据过去一年的财务数据计算其PB，并与米筐的pb_ratio_ttm进行比较。

提取所有股票在2025年底的pb_ratio_ttm，并进行因子的极值处理及标准化处理，画图表示其逐步的处理结果。 注意处理负值，-的PE不是经济学意义上的小PE，将负PE设为无穷大或者使用EP。

# 感谢聆听！

汇报人：黎子