量化投资交易

主讲人：黎新平

北京大学金融工程实验室

第六章

多因子及Barra模型

01

多因子模型

1. 多因子模型：收益贡献分解

- 如前面章节所述，一个股票的收益通常可以分解为多个不同的因子贡献：

$$
\begin{bmatrix} r_1 \\ r_2 \\ \vdots \\ r_N \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} f_c + \left\{ \underbrace{\begin{bmatrix} x_1^{I1} \\ x_2^{I1} \\ \vdots \\ x_N^{I1} \end{bmatrix} f_{I_1} + \cdots + \begin{bmatrix} x_1^{Ip} \\ x_2^{Ip} \\ \vdots \\ x_N^{Ip} \end{bmatrix} f_{I_p}}_{P\text{类行业因子}} \right\} + \left\{ \underbrace{\begin{bmatrix} x_1^{S1} \\ x_2^{S1} \\ \vdots \\ x_N^{S1} \end{bmatrix} f_{S_1} + \cdots + \begin{bmatrix} x_1^{Sq} \\ x_2^{Sq} \\ \vdots \\ x_N^{Sq} \end{bmatrix} f_{S_q}}_{Q\text{类风格因子}} \right\} + \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_N \end{bmatrix}
$$

投资组合个股益率　常数项　f　残差

因子暴露矩阵　因子收益率　残差

$$
\mathbf{r}_{N\times 1} = \mathbf{X}_{N\times(P+Q+1)} \mathbf{f}_{(P+Q+1)\times 1} + \mathbf{u}_{N\times 1}
$$

- 在上述模型中，投资组合收益率被分解成市场基准回报f_c、行业因子回报f_I、风格因子回报f_S、特定回报(残差)，用矩阵f表示。每一个因子对被分解收益率的贡献是该投资组合在此因子上的风险曝露度，用矩阵X表示。

因而，从收益的归因看，一个股票组合的收益通常需关注以下几个方面：

- 整体市场环境：通过市场基准影响组合的整体收益
- 行业暴露：组合的行业暴露将使得组合收益随着相关行业的整体表现而发生变化；
- 风格特征：一般业内会把行业之外的因子称之为风格因子，如价值、成长等，组合的风格特征将使得组合收益受市场整体风格变化的影响；
- 个股暴露：从量化组合的角度看，如果组合足够分散，个股暴露对于组合收益的影响是非常低的。

从这个角度看，一个足够分散的股票组合相对于市场的超额投资收益，主要决定于其行业暴露以及风格暴露。

02

多因子选股

1. 多因子选股：alpha因子

- 从选股角度，目标投资组合的构建通常可以多个不同因子的组合构建：

$$r = X_{risk} \times f_{risk} + X_{alpha} \times f_{alpha} + \epsilon$$

因而多因子选股通常涉及到两方面的流程：

- Alpha因子的挖掘；
- 风险因子的控制；

2. 多因子选股

单因子

Step1：寻找有效因子

不同的经济环境下，因子的有效性是不断变化的，原先有效的因子当下可能已经衰竭，因此必须不断寻找有效因子

多因子

Step2：因子赋权

通过分析因子风格，建立因子评价体系，对因子赋权，构建多因子模型

投资组合

Step3：股票组合赋权

优化组合权重，并通过模拟测试筛选出最优的股票组合

2. 多因子选股：选因子

在多因子模型中，应该选择什么样的因子来进行选股？

- 因子的长期有效性：因子是否在较长的时间维度内带来明显的超额有益
- 因子的稳定性：因子的表现在不同市场环境中是否一致
- 因子的时效性：因子是否在最近的市场环境中仍能保持良好的表现
- 因子的回撤风险：因子的回撤风险有多大
- 因子的与其他因子的相关性：因子是否与模型中其他因子高度相关

2. 多因子选股：关于因子的一些观察

不同因子的重要性、有效性不尽相同。

因子具有时效性，受宏观环境 、均值修复等影响。

从美国市场看，一些因子有效性在逐渐下降。

同样因子，不同构建方式有时会产生非常不同的结果。

做多组合与多空组合表现不尽相同，多空组合不一定风险更低。

某些因子存在较大的尾巴风险， 比如趋势投资(momentum)。

因子有效性具有地域性，不同国家或地区因子表现并不一致。

因子间是相关的，且不一定是线性关系。

2. 多因子选股：因子的适用环境

国内市场：

- 动量因子:

2010-2013：动量效应
2014-2016下半年：反转效应
2017-2025：动量效应

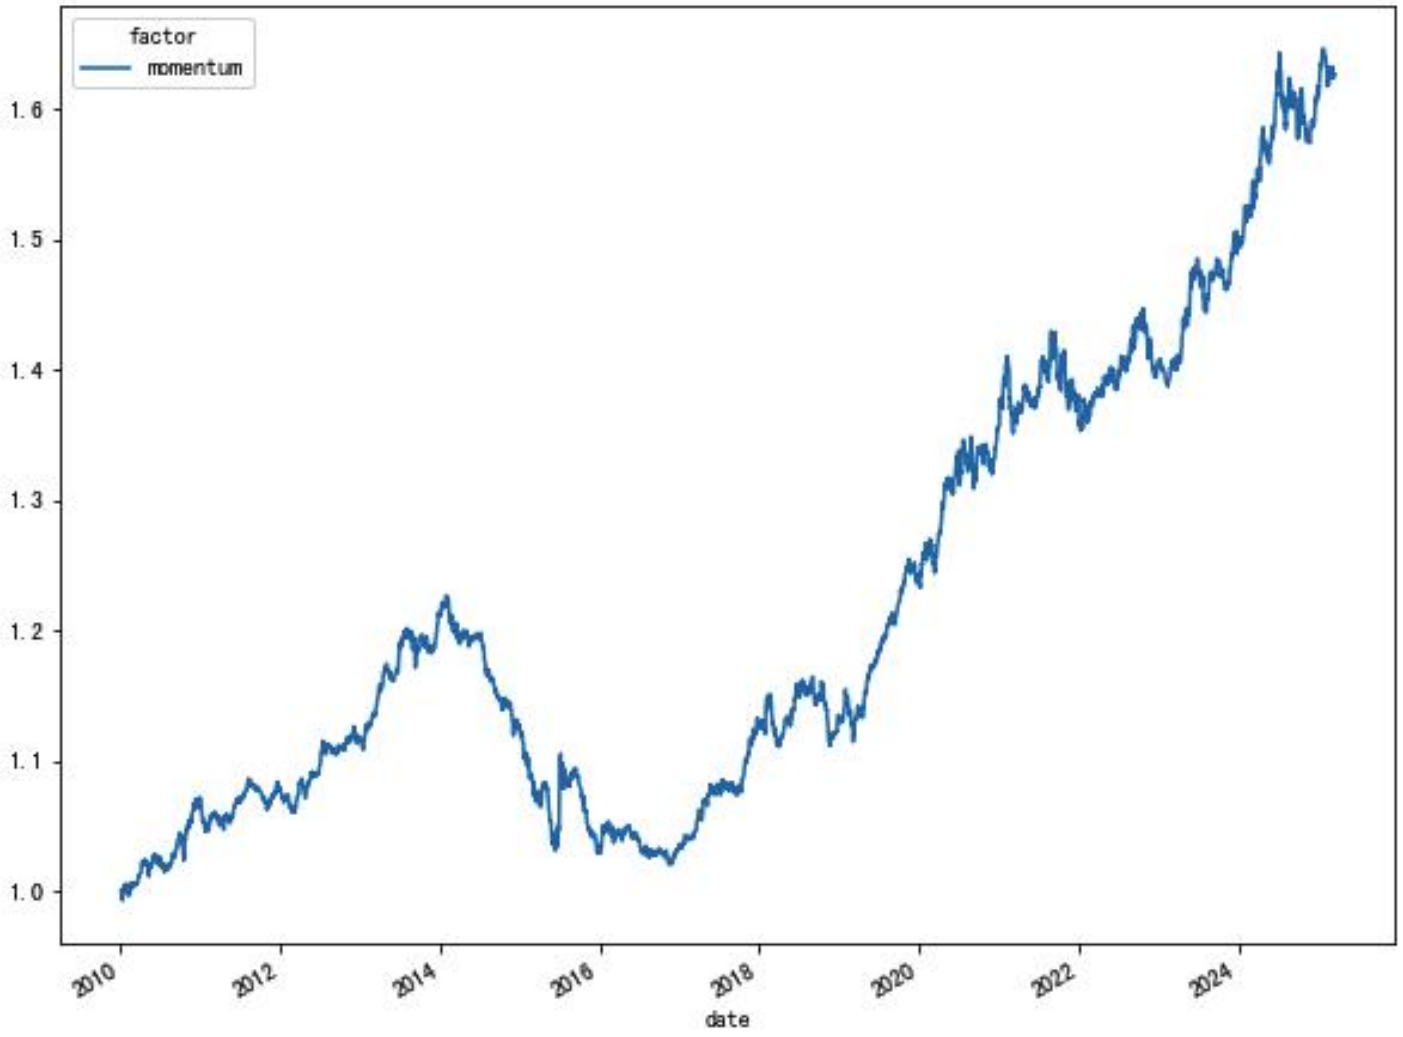

2. 多因子选股：因子的适用环境

国内市场：

- 市值因子：

2010-2016下半年：小市值效应
2016-2021：小市值效应失效
2021-2025：小市值效应

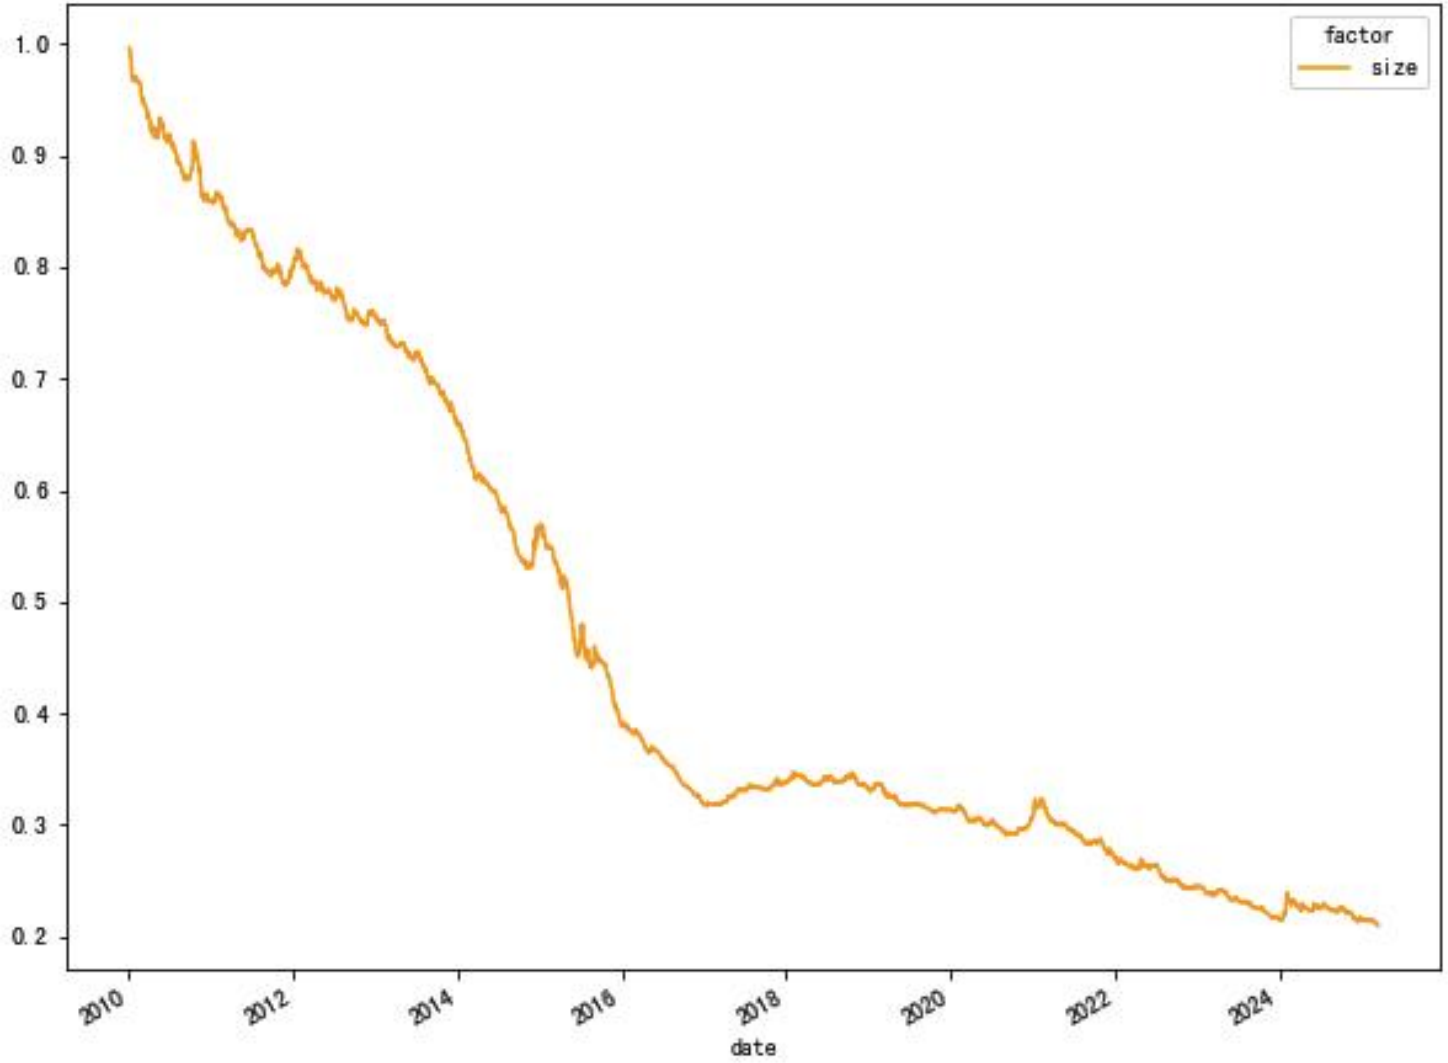

2. 多因子选股：因子的适用环境

投资组合实际上是构建因子的组合

风险因子的联动

宏观因子

经济增长

通货膨胀

流动性

波动率

因子配置

因子风险溢价与经济情景的关系

不同宏观情景下的因子组合

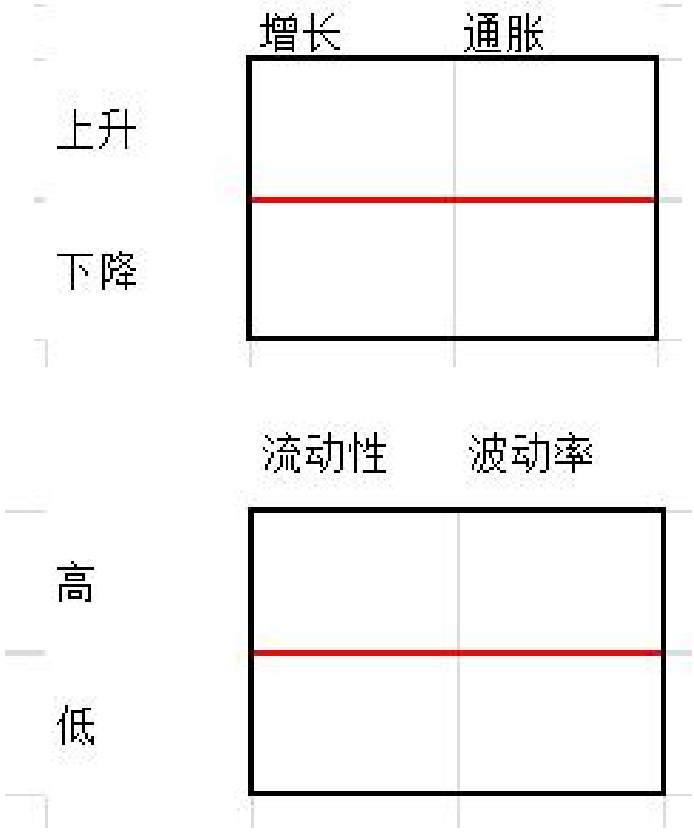

2. 多因子选股：国内常见的长效因子

	沪深300全收益	成长	低波	价值	红利	质量	质量 + 价值全收益
2010	-11.58%	1.47%	-16.29%	-17.04%	-16.30%	-11.88%	-4.36%
2011	-24.05%	-30.02%	-13.14%	-15.35%	-14.20%	-16.38%	-21.71%
2012	9.80%	12.25%	6.12%	7.45%	6.62%	8.70%	4.64%
2013	-5.33%	11.91%	-4.60%	-6.98%	-5.43%	-1.11%	4.91%
2014	55.85%	50.86%	68.67%	63.40%	62.62%	46.29%	57.47%
2015	7.22%	27.54%	17.10%	11.41%	9.01%	17.88%	22.05%
2016	-9.26%	-13.20%	-2.19%	-4.45%	-4.31%	-8.21%	-2.30%
2017	24.25%	3.65%	21.49%	22.77%	24.63%	26.94%	31.99%
2018	-23.64%	-26.19%	-16.98%	-19.10%	-14.55%	-22.29%	-20.69%
2019	39.19%	36.03%	20.39%	23.92%	24.15%	44.62%	34.32%
2020	29.89%	33.97%	12.64%	5.05%	8.49%	42.64%	20.01%
累计收益率	81.56%	107.67%	94.54%	57.84%	76.19%	155.14%	160.41%
年化	5.10%	6.28%	5.70%	3.88%	4.83%	8.12%	8.30%
年化波动率	23.33%	26.21%	19.43%	21.29%	20.37%	20.96%	19.99%
胜率	-	45.45%	54.55%	45.45%	54.55%	72.73%	72.73%

2. 多因子选股：复合因子

在确定模型因子之后，在进行因子选股之前，往往需要对所选择的因子进行汇总，选股的复合因子指标。

- 等权重因子组合：

$$F_\alpha = \sum \frac{1}{N} * X$$

- 最小波动因子组合：

$$W = \arg\min Var(W * F)$$

因子收益率

$$F_\alpha = W * X$$

- 最大化信息比率因子组合：

$$W = argmax\, W'F/\sqrt{W'\Sigma W}$$

$$F_\alpha = W * X$$

2. 多因子选股：机器学习方法合成

因子之间不一定通过线性关系合成，因子间可能存在更复杂的非线性关系。 因而在实践中，往往会采用机器学习方法或深度学习方法进行因子的合成计算。

- 随机森林方法：

核心思想：将未来股票收益作为目标变量，将标准化后的多个因子作为输入特征，训练一个随机森林回归模型，最终用模型对每只股票的预测值作为“合成因子”得分。

注意：

- 因子需预先完成去极值、标准化、行业中性化等预处理；
- 滚动窗口训练（如每月或每季更新模型），避免合成因子用到未来数据；
- 可结合SHAP值等工具增强可解释性

python

```python
from sklearn.ensemble import RandomForestRegressor
# X: 标准化后的因子矩阵 (N_stock × N_factor)
# y: 下一期股票收益率
model = RandomForestRegressor(n_estimators=200, max_depth=8, random_state=42)
model.fit(X_train, y_train)
composite_score = model.predict(X_universe)  # 合成因子得分
```

2. 多因子选股：机器学习方法合成

- 深度学习方法：

$$\text{Score} = f_L(W_L \cdot f_{L-1}(\cdots f_1(W_1 \cdot \mathbf{F} + b_1)\cdots) + b_L)$$

其中 $\mathbf{F}$ 为因子向量， f_i 为激活函数。

优势：
- 强非线性表达能力：可拟合任意连续函数；
- 端到端优化：可直接以IC、夏普比率等为目标损失函数；
- 易于引入正则化：如Dropout、权重衰减、正交惩罚等，提升泛化性。

注意：
- 输入因子须标准化（Z-score或Rank），否则梯度不稳定；
- 损失函数优化：如使用IC损失比普通MSE()效果更稳定些；
- 隐藏层不宜过深（2–3层足够），避免小样本过拟合。

```python
# 定义 MLP 模型
model = nn.Sequential(
    nn.Linear(10, 64), nn.ReLU(),
    nn.Linear(64, 32), nn.ReLU(),
    nn.Linear(32, 1)
)

# 训练模型（仅用训练集）
optimizer = torch.optim.Adam(model.parameters())
criterion = nn.MSELoss()
for _ in range(50):
    optimizer.zero_grad()
    loss = criterion(model(X_train), y_train.unsqueeze(1))
    loss.backward()
    optimizer.step()

# 在测试集上生成合成因子得分
with torch.no_grad():  # 推理时不计算梯度
    composite_score = model(X_test).squeeze()
```

2. 多因子选股：打分排序

在确定模型因子之后，便可以根据所选择的因子进行选股。

打分排序法选股：

一种简单的选股方法是因子打分排序法，具体如下：

(1) 按照所选股的因子组合构建复合因子；

(2) 根据复合因子对股票池里的股票进行排序；

(3) 选前面N个股票；

(4) N个股票等权重构建投资组合；

2. 多因子选股：打分排序

打分排序法的选股过程也可以通过数学优化的方式实现：

复合因子构建：

$$F_\alpha = \sum \frac{1}{N} * X$$

构建投资组合：

$$max \quad w' F_\alpha$$
$$s.t.$$
$$0 \le w \le \frac{1}{N} \quad (1)$$
$$\sum w = 1 \quad (2)$$

在上述约束条件中，（1）表示每个股票的权重最高不能超过1/N，并且不允许做空； 条件（2）则要求所有股票权重加总为1。

2. 多因子选股：简单优化器

线性优化选股：

在实际投资中，为了控制组合的风险暴露，常常会需要通过优化的方法进行股票的选择。一个简单的选股方式如下所示：

复合因子：$F_\alpha = \sum \frac{1}{N} * F$

优化选股：

$$
\begin{aligned}
&\max w' \mathrm{F}_\alpha \\
&s.t. \\
&sl \le Xw \le s\mathrm{h} \quad (1) \\
&kl \le Iw \le k\mathrm{h} \quad (2) \\
&wl \le w \le w\mathrm{h} \quad (3) \\
&1'w = 1 \quad (4)
\end{aligned}
$$

式中，

（1）为因子暴露约束；对于个别因子如小市值、反转等需要控制其暴露程度；

（2）为行业暴露约束， 也即组合内对于某个行业的暴露不能超过一定阈值；

（3）是对于单个股票权重的约束，从而保证组合个股集中度不会太高；

（4）是要求所有股票权重加总为1

2. 多因子选股：简单优化器

最大化风险调整后收益选股：

复合选股因子：$F_\alpha = \sum \frac{1}{N} * F$

优化选股：

$$\max w' \mathrm{F}_\alpha - \lambda\sqrt{(w'X)'\Sigma(w'X)}$$

$$s.t.$$

$$sl \le Xw \le s\mathrm{h} \quad (1)$$

$$kl \le Iw \le k\mathrm{h} \quad (2)$$

$$wl \le w \le w\mathrm{h} \quad (3)$$

$$1'w = 1 \quad (4)$$

式中，

（1）为因子暴露约束；对于个别因子如小市值、反转等需要控制其暴露程度；

（2）为行业暴露约束， 也即组合内对于某个行业的暴露不能超过一定阈值；

（3）是对于单个股票权重的约束，从而保证组合个股集中度不会太高；

（4）是要求所有股票权重加总为1

2. 多因子选股：选股流程

动态多因子模型

- 多策略模型
- 较好的与基本面因素结合：公司、宏观、流动性
- 因子的动态选择反映了经济情况的变化
- 因子退出和量化止损

因子构建
- 行业
- 基本面： 估值、盈利、增长
- 风险状况：资本结构、波动率
- 交易情况：换手、趋势

因子选择及组合
- 有效性、时效性、稳定性
- 宏观条件
- 风险及优化

选股
- 流动性
- 分散性
- 组合优化

量化止损
- 因子退出
- 宏观环境
- 量化波动止损、对冲调整

03

Barra模型

Barra模型简介

从1975年开始，Barra公司便开始利用先进的技术和高效的建模能力，为全球客户提供全方位的风险管理解决方案，其为全球不同国家和地区设计了覆盖收益预测、风险分析、组合构建、交易成本分析以及历史绩效归因等功能的软件产品以帮助用户改善组合绩效。

Barra除了公布其理论说明书The Barra Equity Model外，还发布了一套收费的Barra Aegis系统供全球投资者使用，系统功能完全基于Barra多因子模型，主要包括以下四大模块：

1、Aegis Portfolio Manager：用于分析股票投资组合的前瞻性风险；
2、Aegis Optimizer：用于最优化投资策略的风险收益比；
3、Aegis Performance Analyst：用于解释基金收益的来源；
4、Aegis Developer’s Toolkit：用于对投资理念进行回溯测试。

3. Barra模型：CNE5模型

根据Barra 模型，股票的收益率可以分解被三大类因素所解释，分别是国家、行业及风格。

$$r_n = f_c + \sum_i X_{ni} f_i + \sum_s X_{ns} f_s + u_n$$

CNE5包括：

- 1 个国家因子：常数项；
- 32个行业因子：GICS行业分类；
- 10个风格因子：MSCI常用风格因子，包括21个小类因子；

3. Barra模型：CNE5模型

Barra 中国股票模型(CNE5)因子架构（1）

- 国家因子
- 风格因子
  - Size: 捕捉大盘股和小盘股之间的收益差异
  - Non-linear Size：描述了无法由规模因子解释的但与规模有关的收益差异，通常代表中盘股
  - Earnings Yield：描述了由盈利收益导致的收益差异
  - Book-to-Price：描述了股票估值高低不同而产生的收益差异, 即价值因子
  - Growth：描述了对销售或盈利增长预期不同而产生的收益差异
  - Leverage：描述了高杠杆股票与低杠杆股票之间的收益差异
  - Momentum (动量)：描述了过去半年到一年里相对强势的股票与弱势股票之间的差异
  - Beta：捕捉那些无法用国家因子解释的市场风险
  - Residual Volatility：解释了剥离了市场风险后的波动率高低产生的收益率差异
  - Liquidity：解释了由股票相对的交易活跃度不同而产生的收益率差异

3. Barra模型：CNE6模型

Barra 模型在2018年8月发布了CNE6，将因子进一步细分和扩充，构建了包括 9 个一级风格因子，20 个二级基础因子，46 个三级因子的三层风格因子体系。

$$r_n = f_c + \sum_i X_{ni} f_i + \sum_s X_{ns} f_s + u_n$$

CNE6建立了三级因子体系，其中

- 1 个国家因子：常数项；
- 32个行业因子：GICS行业分类；
- 三级风格因子：

  一级因子9个，
  二级因子20个，
  三级因子46个。

  上层因子是由下层因子加权计算得到。

3. Barra模型：常用因子指标

BARRA STYLE FACTOR STRUCTURE

VOLATILITY	QUALITY	MOMENTUM	VALUE	SIZE	GROWTH	LIQUIDITY	SENTIMENT
Beta ● Hist Beta **Residual Volatility** ● Hist Sigma ● Daily Std Dev ● Cumulative Range	**Leverage** ● Debt to Assets ● Book Leverage ● Mkt Leverage **Profitability** ● Asset Turnover ● Profitability ● Profit Margin ● Return on Assets **Earnings Variability** ● Variation in Sales ● Variation in Earnings ● Variation in Cash Flow ● Variation in Fwd EPS **Earnings Quality** ● Accruals - B/S Statement ● Accruals - C/F Statement	**Momentum** ● Rel Strength ● Hist Alpha **Industry Momentum** ● Industry Momentum **Short-Term Reversal** ● Short-Reversal **Seasonality** ● Quarterly Seasonality ● Annual Seasonality	**Book-to-Price** ● Book-to-price **Earnings Yield** ● Reported E/P ● Forecasted E/P ● Cash E/P ● EBIDTA/EV ● *Reported D/P* ● *Forecast D/P* **Long-Term Reversal** ● LT Rel Strength ● LT Hist Alpha	**Size** ● Log of Market Cap **Mid Cap** ● Cube of Size	**Growth** ● Sales Growth ● Earnings Growth ● Forecast LTG	**Liquidity** ● 1m Turnover ● 3m Turnover ● 12m Turnover ● 12m ATVR	**Analyst Sentiment** ● Revision Ratio ● Change in Analyst-Predicted E/P ● Change in Analyst-Predicted EPS

3. Barra模型：纯因子收益率

在定义了相关因子之后，便需要计算纯因子收益率。Barra模型对以下方程进行回归，从而得到各因子相应的收益率。把每个因子的收益率进行复合，便可以得到各因子的累计收益率走趋。

$$r_{n+1} = f_c + \sum_i X_{ni} f_i + \sum_s X_{ns} f_s + u_n$$

$$s.t. \quad \sum_i w_i f_i = 0$$

上式中，w_i是各行业的市值权重，约束条件表示各行业收益按市值权重加总后为零。

问题：

（1）约束$\sum_i w_i f_i = 0$？
如果没有这一约束，那么行业收益和市场整体收益就完全线性相关了。

（2）为什么是纯因子收益率？

$$R = Xf + u$$

根据回归系数公式有：

$$f = (X'X)^{-1}X'R$$

$$= W'R$$

也即因子收益 f 可以表示成股票组合 W' 的收益， 其中，

$$W' = (X'X)^{-1}X'$$

第i个因子组合的股票权重为：

$$W_i' = ((X'X)^{-1}X')_i$$

既然因子收益可以看作投资组合的组合收益，那么我们可以得到每个组合 i 的因子暴露：

$$(W'X)_i = ((X'X)^{-1}X'X)_i = I_i$$

也即，该组合只在第i个因子上有所暴露，在其他因子上的暴露为0。

3. Barra模型：纯因子收益率

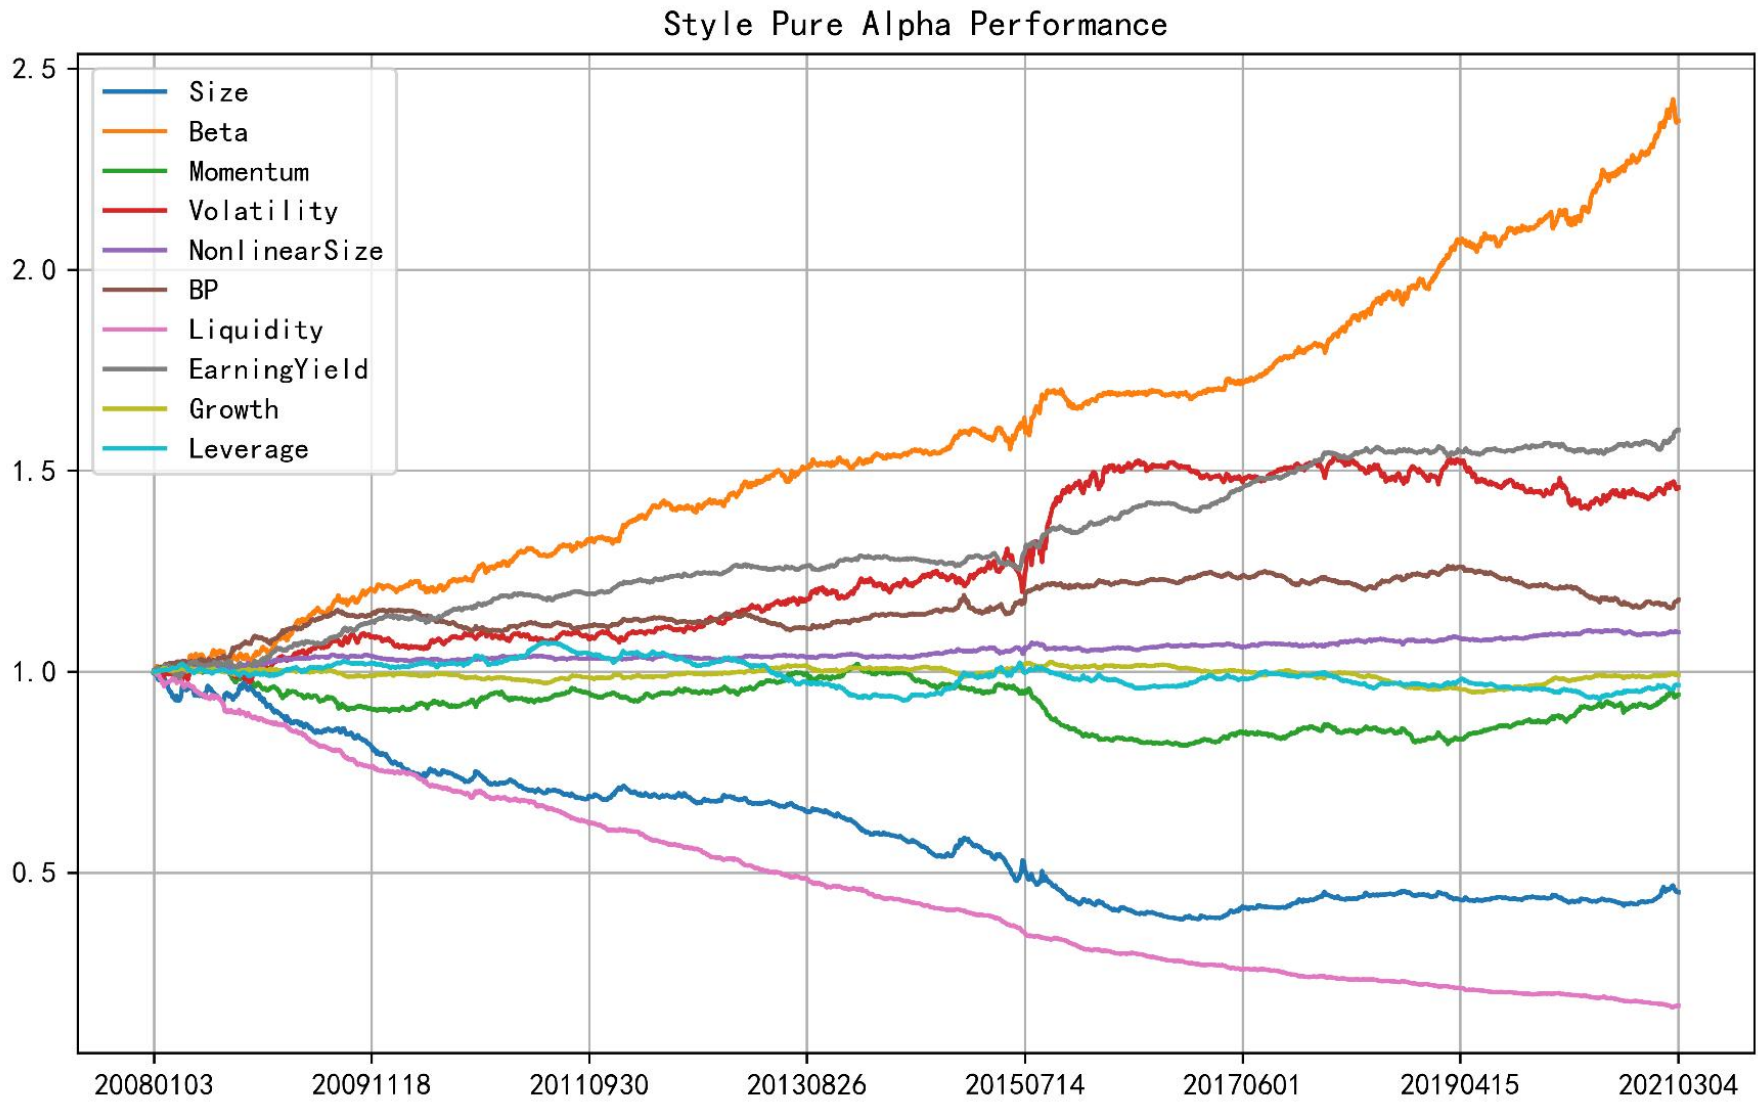

3. Barra模型：纯因子收益率

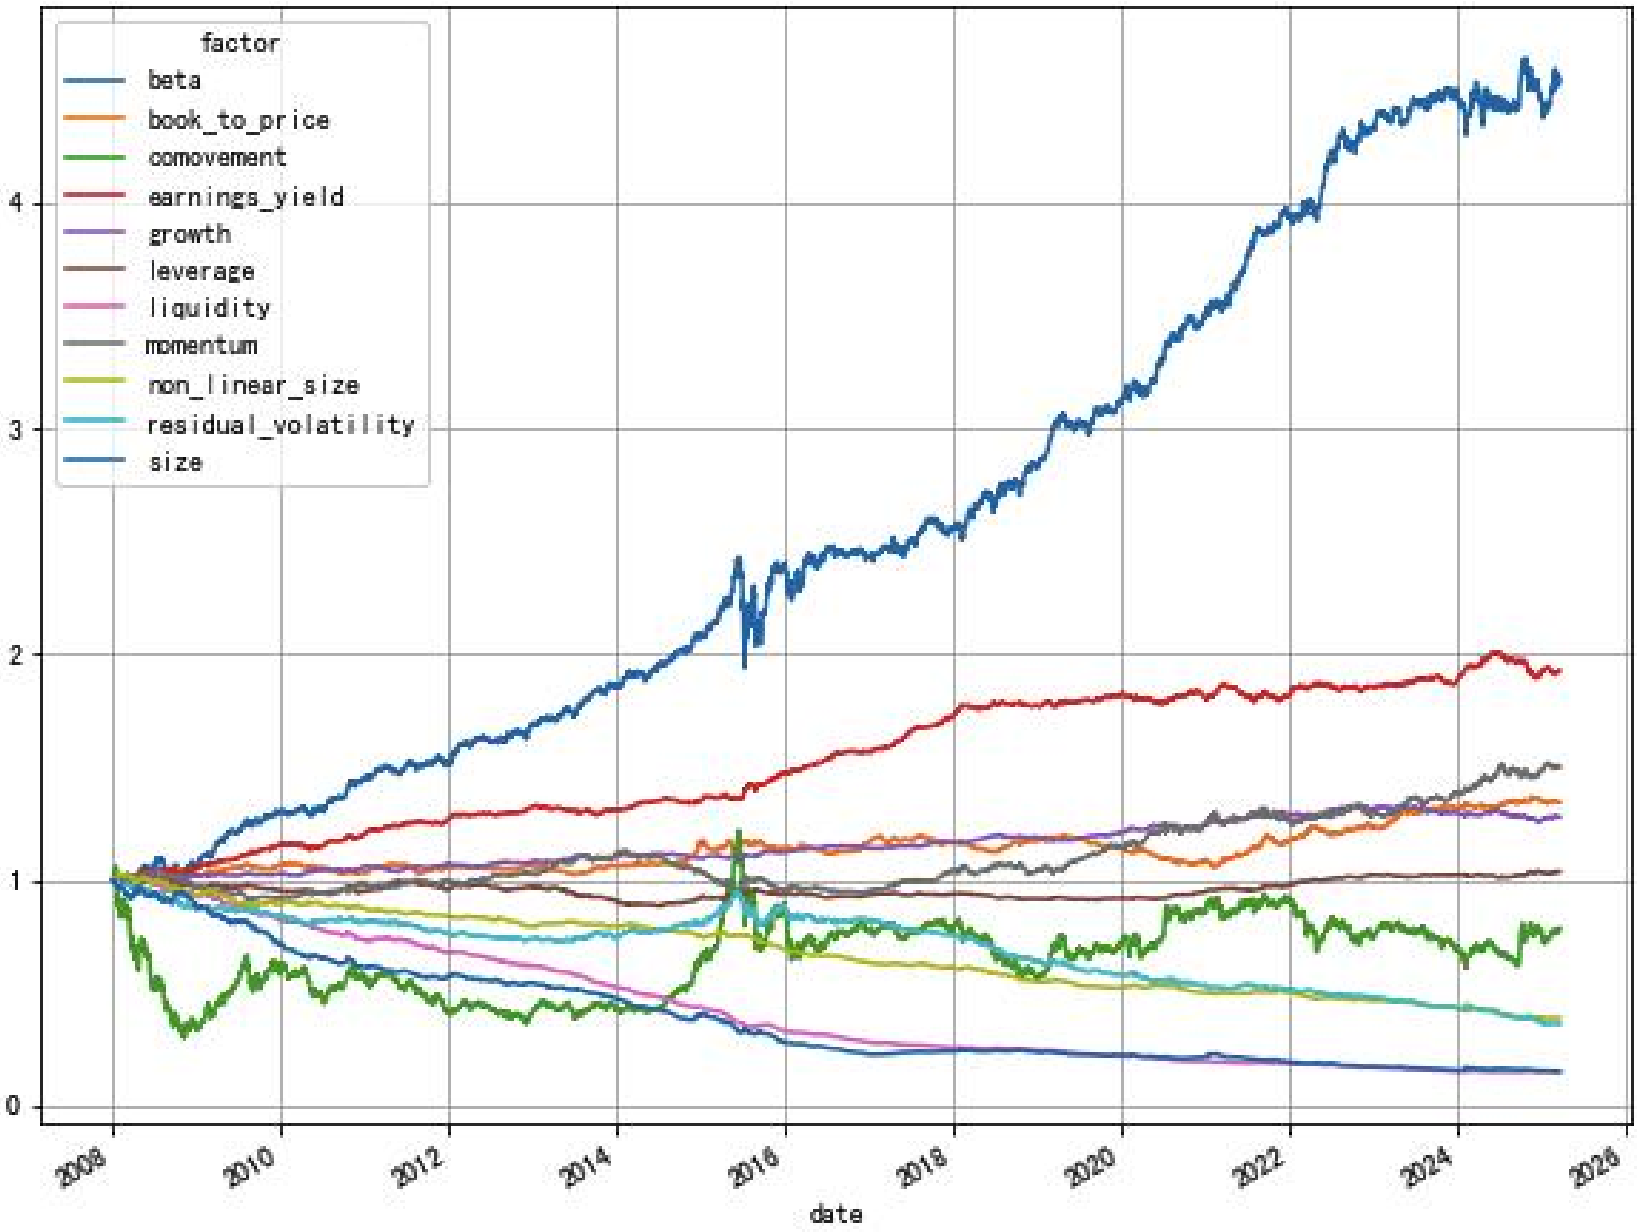

3. Barra模型：风险模型

(1) 风险因子的分解

假设有N只股票，这 N只股票的收益受 K个因子驱动。可以对股票收益率 r 建立多因子模型：

$$r = X * f + \varepsilon$$

式中， r 是股票相对于无风险利率的超额收益率（ N维列向量），X是因子暴露度（NxK维矩阵），f是因子收益率（ K维列向量）， ε 是特异收益率（ N维列向量）。

基于如下假设：

A1. 特异收益率 ε 和因子收益率 f 不相关，即$cov(\varepsilon_n, f_k) = 0$, 对任意 n 和k都成立
A2. 任意两只不同股票的特异收益率之间互不相关，即 $cov(\varepsilon_i, \varepsilon_j) = 0$ 对任意 $i \neq j$ 都成立
可以完成多因子风险模型的定义，将 NxN 维的股票收益率协方差矩阵 V 表示为：

$$\begin{aligned}
V &= Var(r) \\
&= Var(X * f + \varepsilon) \\
&= Var(X * f) + Var(\varepsilon) + Cov(X * f, \varepsilon) \\
&= XVar(f)X + var(\varepsilon) \\
&= X\Sigma X + \Delta
\end{aligned}$$

(2) 投资组合的风险

任意一个投资组合 x_p 都可以由一个 N维向量 w_p ，其中 w_p 是该组合在 N 只风险资产上的持仓权重，组合 x_p 的因子暴露度由下式给出

$$x_p = X * w_p$$

投资组合 x_p 的方差为:

$$Var(r_p) = w_p Var(r) w_p$$

$$= w_p V w_p$$

$$= w_p X \Sigma X w_p + w_p \, \Delta \, w_p$$

04

程序篇：多因子选股--漂亮50

4. 量化故事：巴菲特的Alpha

- 这篇名为“巴菲特的阿尔法（Buffett's Alpha）”的论文得到了广泛的关注，他们将巴菲特价值投资策略带来的超额收益，使用因子模型对巴菲特的阿尔法进行归因，最后将出色的回报归结为低估值、低风险和高质量三种因素共同作用的结果

Financial Analysts Journal | A Publication of CFA Institute

OPEN ACCESS

Research

Buffett's Alpha

Andrea Frazzini, David Kabiller, CFA, and Lasse Heje Pedersen

Andrea Frazzini is a principal at AQR Capital Management, Greenwich, Connecticut. David Kabiller, CFA, is a founding principal at AQR Capital Management, Greenwich, Connecticut. Lasse Heje Pedersen is a principal at AQR Capital Management and professor at Copenhagen Business School, Frederiksberg, Denmark.

GRAHAM and DODD

Top Award

- 在A股中对巴菲特因子的回测结果显示，因子有相当出色的选股能力和投资价值，构造因子的多空组合可以取得12.26%的年化收益率，并且这一结论在不同行业以及在控制了其他变量的情况下，依然成立。

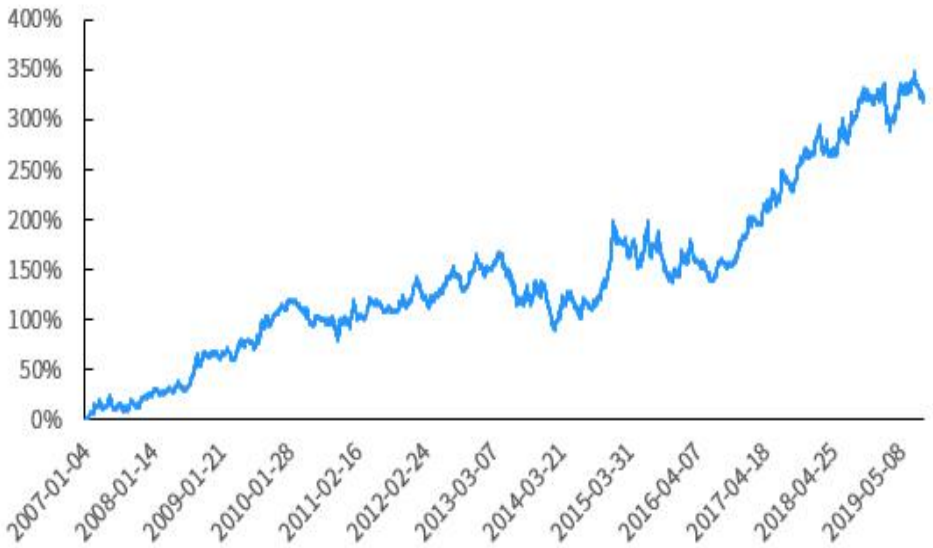

Vibe Coding: 漂亮50策略的实现：

股票池：全市场，剔除退市、停牌及上市不足六个月的股票

选股逻辑：

- 经营业绩好；
- 估值合理；
- 波动风险较低；

选股条件：

- ROE TTM；
- PE TTM（实际选股中用EP TTM);
- volatility in past 60 days;

Vibe Coding: 漂亮50策略的实现

程序流程：

```
1. 确定调仓日期;
rebalace_dates=get_rebalance_dates()

for val_date in rebalance_dates:
    2. 确定股票池；
    secList=get_stocks(val_date)
    3. 构建复合因子
    df=stock_selection(secList,factor_list)
        3.1 提取原始因子值；df_factor=rq.get_factor()
        3.2 标准化处理； df=factor_normalization()
        3.3 因子加权构建复合因子: 简单加权 df.mean()
        3.4 因子排序：df.sort_values()
    4. 根据复合因子选股
    selected_stock[val_date]=df.order_book_id[selected]
```

Vibe Coding: 漂亮50策略的实现

程序流程：

4. 根据复合因子选股

4.1 建立优化函数：最大化复合因子暴露；

```
objective = cp.Minimize()
```

4.2 建立约束条件：行业中性或风险因子约束；

```
constraints = [w >= 0,...]
```

4.3 优化求解得到股票权重；

```
prob = cp.Problem(objective, constraints)
result = prob.solve()
```

感谢聆听！

汇报人：黎子