自回归模型

Outline

1. 差分方程
2. 自回归模型的性质
3. 自回归模型的识别
4. 自回归模型的应用

$$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} + \varepsilon_t，\quad \varepsilon_t为模型误差$$

- y对它自己历史的回归模型，即自回归(autoregressive, AR)模型
- 我们讨论AR模型有以下几个理由：
  - 帮助我们了解时间序列数据的平稳性和遍历性问题
  - 是最简单的时间系列模型，帮助我们了解时间序列模型的参数估计，模型选择及预测

1 差分方程

- 为了更好地理解AR模型$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} + \varepsilon_t$，我们先看它的确定性部分：$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}$
- 这是一个差分方程差分方程：　　$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}$
- 因为AR（p）的许多性质与差分方程类似，比如条件均值。而差分方程容易分析得多，我们先讨论这个差分方程
- 这是一个线性常系数非齐次p阶差分方程
- 差分方程是描述动态系统的重要工具，这里的线性差分方程是其中最简单的一种。
  - 前面提到的混沌现象就是其中的另一种。

- 差分方程理论告诉我们，对线性常系数非齐次p阶差分方程

$$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} \qquad (1)$$

它对应的齐次p阶差分方程为 $\cdot y_t = \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}$ (2)

- 定理一：对方程（2），如果$f_1(t)$，$f_2(t)$，$\cdots$ $f_p(t)$ 是它的一组线性无关的解，那么方程（2）的任何解一定可以表示成这p个解的线性组合$f(t) = c_1 f_1(t) + c_2 f_2(t) + \cdots + c_p f_p(t)$。不定系数$c_i$由初始条件决定。
- 定理二：对方程（1），如果$f_1(t)$，$f_2(t)$，$\cdots$ $f_p(t)$ 是它对应的齐次差分方程（2）的线性无关的解，g(t)是方程（1）的一个特解，那么方程（1）的任何解一定可以表示成

$$f(t) = c_1 f_1(t) + c_2 f_2(t) + \cdots + c_p f_p(t) + g(t)$$

- 这两个定理告诉我们，为了求解差分方程（1），只需要找出对应的线性无关解组和一个特解。
  - 因此，我们可以用猜解的方法。

- 对方程： $y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}$ （1） 它对应的齐次p阶差分方程为 $y_t = \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}$ (2)
- 先用猜解方法求非齐次差分方程（1）的特解：
  - 当$\beta_1 + \cdots + \beta_{\mathrm{p}}$不等于1时， 猜 $y_t = g(t) = \mathrm{B}$，代入差分方程（1），从而有 B $=\alpha/(1-\beta_1-\cdots-\beta_p)$
  - 当$\beta_1 + \cdots + \beta_{\mathrm{p}}$等于1并且$\beta_1 + 2\beta_2 \cdots + p\beta_p$不等于0 时， 猜 $y_t = g(t) = \mathrm{B}t$，代入差分方程（1），有 B $=\alpha/(\beta_1 + 2\beta_2 \cdots + p\beta_p)$
  - 当$\beta_1 + \cdots + \beta_{\mathrm{p}}$等于1并且 $\beta_1 + 2\beta_2 \cdots + p\beta_p$等于0， 猜？
  - 我们只需要$\beta_1 + \cdots + \beta_{\mathrm{p}}$不等于1时的特解$g(t)$（后面讲到）
- 下面再猜通解

$$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} \quad (1) \qquad y_t = \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} \quad (2)$$

- 再用猜解方法求齐次差分方程（2）的解：猜 $y_t = Az^t$，代入差分方程(2)，有

$$Az^t = \beta_1 Az^{t-1} + \beta_2 Az^{t-2} + \cdots + \beta_p Az^{t-p}$$

  - 即 $z^p - \beta_1 z^{p-1} - \cdots - \beta_{p-1} z - \beta_p = 0$ （3）
  - 这是一个普通的一元p次多项式方程。有p个解，z_i，$i=1,2,\cdots,p$
  - 如果p个解z_i （$i=1,2,\cdots,p$）都不相同，那么我们找到了差分方程（2）p个线性无关的解$y_t = z_i{}^t$，从而得到差分方程（2）的解
  - 如果p个解z_i （$i=1,2,\cdots,p$）中某个解z_k重复了n次，那么这p个解不是线性无关。例子 y_t = 2y_{t-1} - y_{t-2}
  - 这时可以容易地验证，$z_k t^j, j = 1, \ldots, n-1$，也是差分方程（2）的解，并且显然它们线性无关。例子
  - 这样我们就找到了差分方程（2）的全部解。从而找到了差分方程（1）的全部解：$y_t = g(t) + \sum_{i=1}^{p} C_i z_i{}^t$ 其中某些$z_i{}^t$可能由$z_i{}^t\, t^j$替代。
- 显然，求解过程中，一元p次多项式方程（3）起到了重要作用。我们把方程（3）称作差分方程（1）的特征方程。
- 通过这个特征方程，我们可以求解线性差分方程所刻画的动态系统

- 差分方程的稳定性：对动态系统来说，最重要的特性之一是系统的稳定性
- 稳定性的一个重要表现是，当时间t趋向无穷时，状态y_t是否收敛
  - 如果收敛到一个有限数，稳定。因为改变初始位置一些，足够时间后，没有差别.
  - 如果趋向无穷，不稳定。可能导致所谓的“蝴蝶效应”
  - 如果一直在某个区间跳跃，可能形成混沌现象
  - 微观经济学中的“蛛网模型”，三种情况

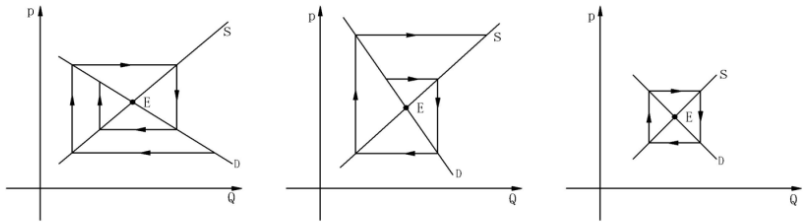

- 差分方程：
  - 需求 $D_t = a P_t + b$， 供给 $S_{t+1} = c P_t + d$，均衡：$S_{t+1}=D_{t+1}$
  - 动态过程： $c P_t + d = a P_{t+1} + b$， $P_{t+1} = \frac{c}{a} P_t + \frac{d-b}{a}$
- 关于系统的稳定性问题，动态系统理论有一系列的研究。

光华管理学院
Guanghua School Of Management

- 对我们这里的线性常系数差分方程来说，稳定性问题非常简单。因为我们有显式解
- 差分方程$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}$，它的解为$y_t = g(t) + \sum_{i=1}^{p} C_i z_i{}^t$ 其中某些$z_i{}^t$可能由$z_i{}^t\, t^k$替代，
  - 先看通解部分项。它们都是$z_i{}^t$或者 $z_i{}^t t^k$。时间t趋近无穷大时，如果所有的z_i为实数且绝对值小于1，那么$z_i{}^t$或者 $z_i{}^t t^k$都趋近0
  - 而如果所有的z_i为实数且绝对值小于1， $\beta_1 + \cdots + \beta_p$肯定不等于1，要不然特征方程会有一个根等于1
  - 这时第一项g(t)，为$\frac{\alpha}{1-\beta_1-\cdots-\beta_p}$，常数，收敛
  - 因此，如果所有的z_i为实数且绝对值小于1，系统y_t趋近到$\frac{\alpha}{1-\beta_1-\cdots-\beta_p}$ ，稳定
    - 这里也可以看出我们不需要考虑“当$\beta_1 + \cdots + \beta_p$等于1并且 $\beta_1 + 2\beta_2 \cdots + p\beta_p$等于0”的特解
  - 如果z_i是复数，类似，只要它的模小于1，那么$z_i{}^t$或者 $z_i{}^t t^k$都趋近0
  - 综合实数根与复数根情况，z_i在单位圆之内
  - 而z_i是差分方程的特征方程的根，因此，差分方程稳定的充分条件是特征方程的根在单位圆内.

- 差分方程$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}$
- 有些课本上说“差分方程稳定性的条件为其特征方程的根在单位圆外”
  - 其原因是他们定义的特征方程是：$1 - \beta_1 z \cdots - \beta_{p-1} z^{p-1} - \beta_p z^p$=0
  - 与我们的$z^p - \beta_1 z^{p-1} - \cdots - \beta_{p-1} z - \beta_p$=0，差别在于自变量互为倒数
  - 因此，我们的解在单位圆内，他们的在单位圆外。都正确
- 他们那样定义特征方程，是由于他们用了滞后算子形式，一个将来非常有用的工具：
  - y_{t-1}=Ly_t， y_{t-2}=Ly_{t-1} =L(Ly_t) $= L^2 y_t$，…
  - 差分方程$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p}$可以表示为（$1 - \beta_1L\cdots - \beta_{p-1}L^{p-1} - \beta_p L^p$）$y_t$=$\alpha$
  - 从而有特征方程（$1 - \beta_1 z \cdots - \beta_{p-1} z^{p-1} - \beta_p z^p$）=0

- 下面看看几个例子：一阶差分方程$y_t = \alpha + \beta y_{t-1}$
  - 由前面通解公式，特征方程z-β=0，差分方程的解为$y_t = \frac{\alpha}{1-\beta} + C\beta^t$
  - 考虑初始条件y_0， $y_0 = \frac{\alpha}{1-\beta} + C$，从而有$y_t = \frac{\alpha}{1-\beta} + (y_0 - \frac{\alpha}{1-\beta})\beta^t$
  - 其实，这里可以用迭代法求解：$y_t = \alpha + \beta y_{t-1} = \alpha + \beta(\alpha + \beta y_{t-2}) = \alpha(1+\beta) + \beta^2 y_{t-2}$
  - $= \cdots = \alpha(1+\beta + \cdots + \beta^{t-1}) + \beta^t y_0 = \frac{\alpha(1-\beta^t)}{1-\beta} + y_0\beta^t$
  - $= \frac{\alpha}{1-\beta} + (y_0 - \frac{\alpha}{1-\beta})\beta^t$
  - 稳定性条件？特征方程的解=β
    - β的绝对值小于1.
    - 考虑蛛网模型，系统稳定的条件是供给曲线斜率小于需求曲线斜率

- 两阶差分方程：$y_t = \alpha + \beta_1 y_{t-1} + \beta_2 y_{t-2}$ ，特征方程 $z^2 - \beta_1 z^1 - \beta_2 = 0$， 两个根：$z_{1,2} = \frac{\beta_1 \pm \sqrt{\beta_1^2 + 4\beta_2}}{2}$
- Case 1：$\delta = \beta_1^2 + 4\beta_2 > 0$
  - 特征方程有两个不同的实根：$z_{1,2} = \frac{\beta_1 \pm \sqrt{\beta_1^2 + 4\beta_2}}{2}$
  - 差分过程为 $y_t = \frac{\alpha}{1-\beta_1-\beta_2} + A_1 z_1^t + A_2 z_2^t$ 。A_1和A_2由初始条件y_0和y_1决定。
  - 这时如果$|z_1| > 1$，或者$|z_2| > 1$, 系统发散。因此原差分过程稳定的条件是特征方程的根的绝对值小于1
- Case 2：$\delta = \beta_1^2 + 4\beta_2 = 0$
  - 特征方程有两个相同的实根：$z_{1,2} = \frac{\beta_1}{2}$
  - 差分过程为 $y_t = \frac{\alpha}{1-\beta_1-\beta_2} + A_1 z_{1,2}^t + A_2 z_{1,2}^t t$
  - 稳定的条件是特征方程的根的绝对值小于1

- 两阶差分方程：$y_t = \alpha + \beta_1 y_{t-1} + \beta_2 y_{t-2}$ ，特征方程 $z^2 - \beta_1 z^1 - \beta_2 = 0$， 两个根：$z_{1,2} = \frac{\beta_1 \pm \sqrt{\beta_1^2 + 4\beta_2}}{2}$
- Case 3：$\delta = \beta_1^2 + 4\beta_2 < 0$
  - 特征方程有两个不同的复数根：$z_{1,2} = \frac{\beta_1 \pm i\sqrt{-\delta}}{2}$,

    这里 z_1, z_2 为共轭复数，并且可以用极坐标表示：

$$z_{1,2} = r(\cos\theta \pm i\sin\theta),\ r = \|z_1\| = \sqrt{a^2+b^2} = \sqrt{-\beta_2}$$

$$\theta = \arccos(\frac{a}{r}) = \arccos(\frac{\beta_1}{2\sqrt{-\beta_2}})$$

  - 差分方程（1）的根还是$y_t = \frac{\alpha}{1-\beta_1-\beta_2} + A_1 z_1^t + A_2 z_2^t$

    可以改写成

$$y_t = g(t) + C_1 r^t(\cos\theta + i\sin\theta)^t + C_2 r^t(\cos\theta - i\sin\theta)^t$$

  - 由于三角函数的值域在 [-1, 1]，显然只要 $r < 1$，解收敛，而

$$r = \|z_1\| = \sqrt{(\frac{\beta_1}{2})^2 + (\frac{\sqrt{-\delta}}{2})^2} = \frac{1}{2}\sqrt{\beta_1^2 - \delta} = \sqrt{-\beta_2}$$

  - 还是特征方程的解的模小于

- 差分方程的周期性

  - 对两阶差分方程：$y_t = \alpha + \beta_1 y_{t-1} + \beta_2 y_{t-2}$ ，特征方程 $z^2 - \beta_1 z^1 - \beta_2 = 0$， 两个根：$z_{1,2} = \frac{\beta_1 \pm \sqrt{\beta_1^2 + 4\beta_2}}{2}$
  - Case 3：$\delta = \beta_1^2 + 4\beta_2 < 0$

$$y_t = g(t) + C_1 r^t (\cos\theta + i\sin\theta)^t + C_2 r^t (\cos\theta - i\sin\theta)^t$$

$$r = \sqrt{a^2 + b^2} = \sqrt{-\beta_2},\ \theta = \arccos(\frac{a}{r}) = \arccos(\frac{\beta_1}{2\sqrt{-\beta_2}})$$

由de Moivre定理，它可以进一步简化：

$$y_t = g(t) + c_1 r^t \cos(\theta t + c_2),$$

这里 c_1，c_2 由 C_1，C_2，β_1，β_2 确定。

由于 cos 是以 2π 为周期的周期函数，$y_t = g(t) + c_1 r^t \cos(\theta t + c_2) = g(t) + c_1 r^t \cos(2\pi + \theta t + c_2) = g(t) + c_1 r^t \cos(\theta(\frac{2\pi}{\theta} + t) + c_2)$。因此，$y_t$ 是以 $\frac{2\pi}{\theta}$ 为周期的周期函数。这一点使得差分过程（进而AR过程）在研究周期性问题中有重要应用。

3 AR过程的性质

- 把扰动项加到差分方程，就是我们的AR模型。
- **先看AR（1）：$\boldsymbol{y_t = \alpha + \beta_1 y_{t-1} + \varepsilon_t}$， 这里$t = \{-\infty \cdots + \infty\}$， $\boldsymbol{E(\varepsilon_t | F_{t-1}) = 0}$**
  - F_t是到时间t时的所有已知信息。为什么要假设$E(\varepsilon_t | F_{t-1}) = 0$？ 之前假设的是E(εt|xt)，如果x_{t-i}与ε相关，就加入模型。为了方便，此处我们增强条件。
  - 平稳（弱平稳）的条件？按定义，应该是均值和协方差不依赖时间
    - 均值：$E(y_t) = \alpha + \beta_1 E(y_{t-1})$+0，即 $\mu_t = \alpha + \beta_1 \mu_{t-1}$
    - 正好是前面讨论过的一阶差分方程
    - 我们知道，如果差分方程平稳（不发散），它的解，在足够远的将来，不依赖于时间。进入稳态。
      - 如果是$t = \{-\infty \cdots + \infty\}$，则任何时间点上，解都不依赖于时间
    - 这就是为什么我们花了些时间讨论差分方程的平稳性问题的原因
    - 方差： $\mathrm{Var}(y_t) = 0 + \beta_1^2 \mathrm{Var}(y_{t-1})$+$\mathrm{Var}(\boldsymbol{\varepsilon_t})$+$\beta_1 \mathrm{Cov}(y_{t-1}, \boldsymbol{\varepsilon_t})$，即$\mathrm{v}_t = \sigma^2 + \beta_1^2 v_{t-1}$一阶差分方程
    - 协方差：$E[(y_t - \mu)(y_{t-k} - \mu)] = 0 + \beta_1 E[(y_{t-1} - \mu)(y_{t-k} - \mu)]$+0，即 $\gamma_{t,k} = \beta_1 \gamma_{t-1,k-1}$
      - 类似于一阶差分方程

- AR（1）：$y_t = \alpha + \beta_1 y_{t-1} + \varepsilon_t$， $E(\varepsilon_t|F_{t-1}) = 0$
  - 平稳（弱平稳）的条件，从均值和方差来看，都是看特征方程：$z - \beta_1$=0， $|z| = |\beta_1| < 1$
  - 平稳时的均值和方差
    - $\mathrm{E}(y_t) = \alpha + \beta_1 E(y_{t-1})$+$E(\varepsilon_t)$, 如果平稳， $\mathrm{E}(y_t) = E(y_{t-1})$=$\mu$，所以有 $\mu = \frac{\alpha}{1-\beta_1}$,
    - 同样有 方差=$\frac{var(\varepsilon)}{1-\beta_1^2}$
    - 从均值和方差也能看出平稳的条件是$|\beta_1| < 1$
    - 这里与齐次差分方程平稳条件的差别是，即使$\alpha = 0$，$|\beta_1|$也不能为1，要不然方差发散。
  - 自回归系数方程：
    - 从协方差方程$\gamma_{t,k} = \beta_1 \gamma_{t-1,k-1}$，平稳时自回归系数方程为：$\rho_1$=$\beta_1$，$\rho_2 = \beta_1^2$， …，$\rho_k = \beta_1^k$
    - 为β_1的指数函数。$\beta_1 = 2$时，很快趋近无穷大，大家知道的中国象棋盘小麦的故事。
      - 同样道理，$|\beta_1| < 1$时快速下降到0。

- 自回归系数方程：ρ_1=β_1，$\rho_2 = \beta_1^2$，…，$\rho_k = \beta_1^k$
  - 显然，这时是弱相关的，即遍历性成立。平稳的AR（1）过程都是遍历的
  - 我们把自相关系数以这种指数函数形式快速下降的过程称作短记忆过程（short memory）
    - 即使β_1=0.95，一阶高度自相关，但k=500时，ρ_k=7.3E-12，几乎为零，几乎没有相关性。
    - 但研究发现，尼罗河水流量的自相关性可以达到上千年。
    - 因此，AR（1）过程显然不适合用来研究这样的问题
  - 与β_1^k形式的指数函数相反，$1/k$下降到0的速度就慢了很多
  - 文献中，把自相关系数以$k^{-a},(\alpha > 0)$,形式慢速下降的过程称作长记忆过程（long memory）。
    - 同学将来可能会碰到的分数单位根过程，就是这样的一个过程。试试Taylor展开（$1-L)^{\frac{1}{2}}y_t = \varepsilon_t$
    - 上世纪60年代有人用这个过程研究股票回报，但后来发现不是很成功。比如30年代的大萧条，对现在的股票回报有影响？
      - 不太可能
      - 但对人们的心理有影响？有可能
        - » 因此，又有人用这个过程研究股票回报波动率

- 自回归系数方程：ρ_1=β_1，$\rho_2 = \beta_1^2$，…，$\rho_k = \beta_1^k$
  - 其实指数函数形式下降，不光在我们的时间序列数据自相关问题中，现金流贴现和宏观经济学中的效用函数贴现也是这样的。
    - 在贴现率=0.95时，100年后的一单位现金（效用），现值=？几乎为零
    - 因此，研究百年大计类的问题，显然不大合适用这样的指数函数贴现。
    - 大概也不太合适用AR（1）这样的模型

- AR（1）$y_t = \alpha + \beta_1 y_{t-1} + \varepsilon_t$也可以表示为$y_t - \mu = \beta_1$（$y_{t-1} - \mu$）$+ \varepsilon_t$ ，$\mu = \frac{\alpha}{1-\beta_1}$
  - 如果$0 < \beta_1 < 1$，这是一个均值回归（mean-reverting）过程.
  - 普适的均值回归现象
  - 0> β_1 >-1 时也是均值回归，但是正负跳跃地回归。不如前面的有持续性（persistence）
  - 半衰期：一个衡量均值回归速度的概念
    - 多长时间（多少期）后过程（离均值的距离）变成它的初始离均值的距离的一半
    - 即，k，使得$E(y_{t+k} - \mu) = 0.5(y_t - \mu)$
  - 对一个AR（1）模型，意味着，即β_1^k $(y_t - \mu)$= $0.5(y_t - \mu)$，可以求出$k = \frac{\ln(0.5)}{\ln(|\beta_1|)}$
    - 例如，β_1=0.5，k=1；β_1=0.9，k=6.6，β_1->1，k->infinifty.
    - 可见，beta决定了均值回归速度，也是持续性的强度
  - 反转交易策略（冲量交易策略）与这里的均值回归（持续性）的区别和联系是什么？
    - 反转交易策略是横截面比较，而不是反转到自己在时间上的平均
    - 因子横截面回归：$r_i = \beta_0 + \beta_1\ rank_i + \varepsilon_i$，i=1,2,⋯,n。发现过去的rank有预测能力，再用rank分组构成long-short组合

Properties of AR（2） process

- AR（2）：$y_t = \alpha + \beta_1 y_{t-1} + \beta_2 y_{t-2} + \varepsilon_t$， 这里$E(\varepsilon_t|F_{t-1}) = 0$
  - 平稳（弱平稳）的条件？同AR（1），要求均值和协方差不依赖时间
    - 均值：$E(y_t) = \alpha + \beta_1 E(y_{t-1}) + \beta_2 E(y_{t-2})$+0，即
      - $\mu_t = \alpha + \beta_1 \mu_{t-1} + \beta_2 \mu_{t-2}$
    - 协方差：$E[(y_t - \mu)(y_{t-k} - \mu)] = 0 + \beta_1 E[(y_{t-1} - \mu)(y_{t-k} - \mu)] + \beta_2 E[(y_{t-2} - \mu)(y_{t-k} - \mu)]$，即
      - $\gamma_{t,k} = \beta_1 \gamma_{t-1,k-1} + \beta_2 \gamma_{t-2,k-2}$
    - 二阶差分方程！
    - 因此，AR（2）过程平稳的条件是其特征方程$z^2 - \beta_1 z - \beta_2 = 0$的解在单位圆内
  - 平稳AR（2）过程的矩条件：
    - 均值：从$\mu_t = \alpha + \beta_1 \mu_{t-1} + \beta_2 \mu_{t-2}$， 有$\mu = \frac{\alpha}{1-\beta_1-\beta_2}$

- AR（2）：$y_t = \alpha + \beta_1 y_{t-1} + \beta_2 y_{t-2} + \varepsilon_t$， 这里$E(\varepsilon_t | F_{t-1}) = 0$
  - 平稳时的方差-协方差：
    - 从$\gamma_{t,k} = \beta_1 \gamma_{t-1,k-1} + \beta_2 \gamma_{t-2,k-2}$， 有K阶自协方差：$\gamma_k = \beta_1 \gamma_{k-1} + \beta_2 \gamma_{k-2}$
    - 自相关系数方程：$\rho_k = \beta_1 \rho_{k-1} + \beta_2 \rho_{k-2}$
      - 二阶差分方程，解的形式为$\rho_k = A_1 a_1^k + A_2 a_2^k$或$\rho_k = A_1 a_1^k + A_2 k a_1^k$
      - 也是指数函数，短记忆过程
      - 遍历性成立
    - 有时我们不用猜解方式求解自相关函数，而用迭代法：
      - K=1时，$\rho_1 = \beta_1 \rho_0 + \beta_2 \rho_{-1} = \beta_1 + \beta_2 \rho_1$
      - 故有Yule-Walker方程：$\begin{cases} \rho_1 = \beta_1 / 1-\beta_2 \\ \rho_k = \beta_1 \rho_{k-1} + \beta_2 \rho_{k-2} \end{cases}$

- AR(p)过程：$y_t = \alpha + \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} + \varepsilon_t$，这里$E(\varepsilon_t | F_{t-1}) = 0$
  - 平稳条件、均值、方差、协方差等的推导过程如AR(2)
  - 特别的，所有的AR（p）过程，都是短记忆过程，都是遍历的
  - 而长记忆问题问题，显然不能用有限阶的AR(p)
- 另外，对AR(p) ， p>=2，特征方程可能有复数根，这时有周期性
- 上面介绍了AR模型的性质，下面讨论AR模型的识别问题。毕竟我们实际工作中，没有模型，只有数据。我们需要用数据识别一个模型

4 AR模型的识别

- 识别AR模型，包括两部分：
  - 模型设置问题 (Order selection)
  - 参数估计问题
  - 我们先讨论给定模型的参数估计问题，因为我们会用估计结果来设置模型
- 在模型给定（阶数给定）的情况下，我们是否可以用OLS来估计模型参数？为什么是个问题？

假定我们有某时间序列的T个样本观测值 $(y_1, y_2, \cdots, y_T)$ 和AR(p)模型 $y_t = \alpha + \beta_1 y_{t-1} + \beta_2 y_{t-2} + \cdots + \beta_p y_{t-p} + \varepsilon_t$ 。模型误差 ε_t 的方差为 σ^2 。初级计量经济学告诉我们，模型参数 $\beta = (\alpha, \beta_1, \cdots, \beta_p)'$ 的OLS估计为：

$$\hat{\beta} = (X'X)^{-1}(XY)$$

$$X = \begin{pmatrix} 1 & y_p & y_{p-1} & \cdots & y_1 \\ 1 & y_{p+1} & y_p & \cdots & y_2 \\ \vdots & \vdots & & & \\ 1 & y_{T-1} & y_{T-2} & \cdots & y_{T-p} \end{pmatrix}, \quad Y = \begin{pmatrix} y_{p+1} \\ y_{p+2} \\ \vdots \\ y_T \end{pmatrix} \qquad (1.13)$$

同时，模型误差的方差估计为：

$$\hat{\sigma}^2 = \frac{1}{T-p-1}\sum_{t=p+1}^{T}\hat{\varepsilon}_t^2$$

$$\hat{\varepsilon}_t = y_t - (\hat{\alpha} + \hat{\beta}_1 y_{t-1} + \hat{\beta}_2 y_{t-2} + \cdots + \hat{\beta}_p y_{t-p})$$

参数估计的方差的估计为

$$\hat{var}(\hat{\beta}|F_T) = (X'X)^{-1}\hat{\sigma}^2$$

- 如果平稳，就是一致估计，就有中心极限定理基础上的检验方法。

- 在模型误差为正态分布时，线性模型主要参数的OLS估计等同于MLE估计
- 为了模型选择的原因和后面ARMA模型估计统一，我们将介绍MLE估计

- 为了简洁起见，我们先考虑AR(1)模型 $y_t = \alpha + \beta_1 y_{t-1} + \varepsilon_t$，这里$E(\varepsilon_t|F_{t-1}) = 0$，假设模型误差 $\varepsilon_t \sim$ iid N(0, σ^2)
  - 未知参数有 $\Phi = (\alpha, \beta_1, \sigma)$ 。假定我们有某时间序列的T个样本观测值 $(y_1, y_2, \cdots, y_T)$ 。
  - 这时联合分布密度函数（似然函数）可以写成：

$$
\begin{aligned}
& f(y_1, y_2, \cdots, y_T|\Phi) \\
= \quad & f(y_T|y_{T-1}, \cdots, y_1, \Phi) f(y_1, y_2, \cdots, y_{T-1}|\Phi) \\
= \quad & f(y_T|y_{T-1}, \cdots, y_1, \Phi) f(y_{T-1}|y_{T-2}, \cdots, y_1, \Phi) f(y_1, \cdots, y_{T-2}|\Phi) \\
= \quad & \prod_{t=2}^{T} f(y_t|y_{t-1}, \cdots, y_1, \Phi) f(y_1|\Phi)
\end{aligned}
$$

在正态分布的模型误差假设下，模型外生性假设 $E(\varepsilon_t|F_{t-1}) = 0$ 意味着 ε_t独立于 F_{t-1} 。因此，条件分布函数 $f(y_t|y_{t-1}, \cdots, y_1, \Phi)$ 为条件正态分布：

$$f(y_t|y_{t-1}, \cdots, y_1, \Phi) = \frac{1}{\sqrt{2\pi}\sigma} \exp(-\frac{(y_t - \alpha - \beta_1 y_{t-1})^2}{2\sigma^2}).$$

并且，利用前面AR(1)过程的矩条件，有

$$f(y_1|\Phi) = \frac{1}{\sqrt{2\pi}\sigma_y} \exp(-\frac{(y_1 - \mu)^2}{2\sigma_y^2}),\ \mu = \frac{\alpha}{1 - \beta_1},\ \sigma_y^2 = \frac{\sigma^2}{1 - \beta_1^2}$$

  - 最大化这个似然函数，就可以得到 Φ 的估计。
  - 对高阶的AR(p)过程，完全类似的方法可以写出似然函数并得出参数的估计

- 首先模拟产生一个AR（1）过程，再去估计它，这样做可以帮助我们了解估计方法的性质和软件
- 模拟产生一个AR（1）过程，需要模拟随机数。但如何产生随机数？
  - 前面提到有两种方法描述不确定性问题：chaos和随机变量。
  - $x_0 = \#$， $x_{n+1} = Mod(7x_n, 10^8)$， $y_{n+1} = x_{n+1}/10^8$, 这样的y就是一组【0,1】均匀分布的（伪）随机数
  - 如果模型误差是正态分布，再用一个正态分布的CDF函数的反函数变换，得到正态分布随机变量
- 我们写一个R方程，这样以后用到时，就不用每次重复写了

```
#模拟一个AR1自回归型时间序列， 模型为y(t)=con+b1*y(t-1)+b2*epsilon,数据长度为n
AR1<-function(con,b1,b2,n){
  set.seed(1000);
  x<-rnorm(n,0,b2) #产生n个均值=0，标准差=b2正态分布的随机数
  y<-0
  y[1]<-con/(1-b1)+x[1]
   for(t in 2:n){
    y[t]<-con+b1*y[t-1]+x[t]
  }
  plot.ts(y,main=paste("y[t]=",con,"+",b1,"*y[t-1]+", "epsilon"))
  y
 }
```

- 这里set.seed可以用，也可以不用

- 然后用这个方程产生一个有500个观测值的样本
  y(t) = 1+0.5*y(t-1)+0.2*epsilon

> *y= AR1(1,0.5,0.2,500)*

- 产生的数据为y

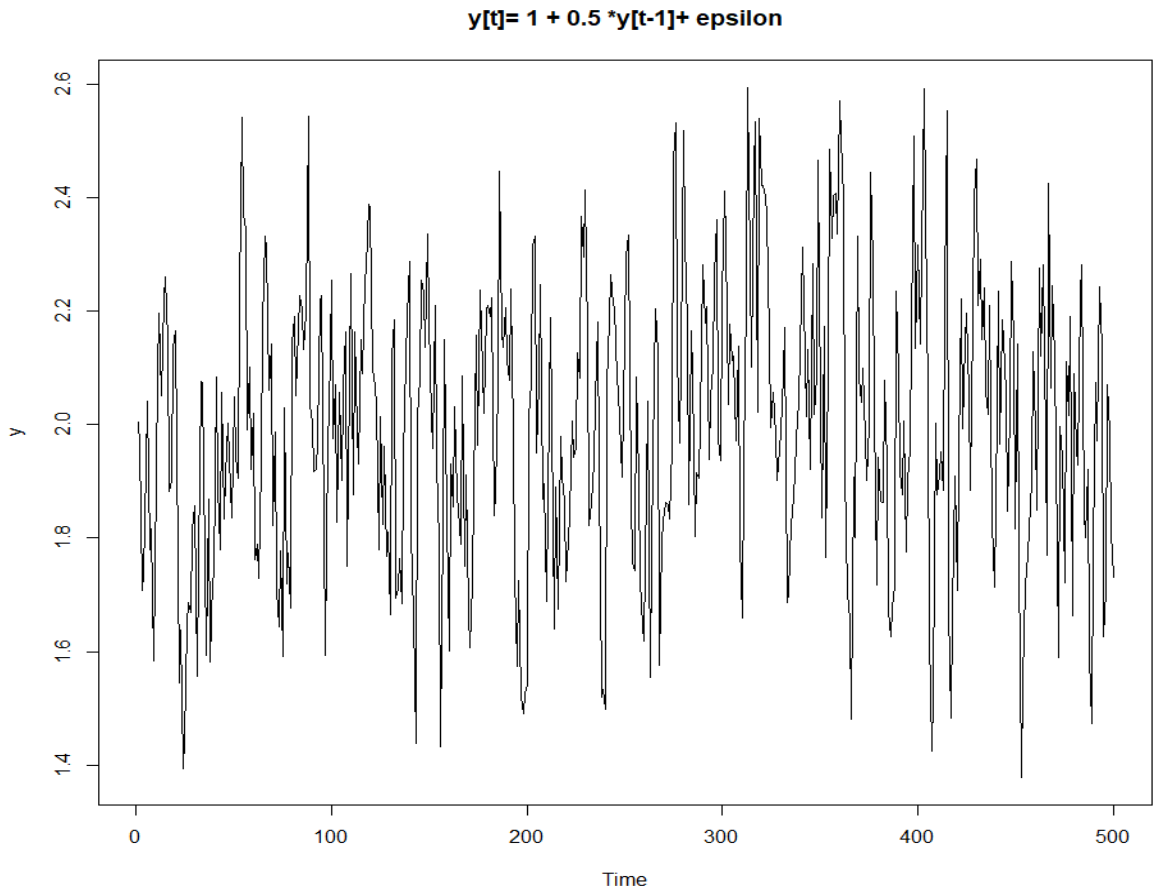

y(t) = 1+0.5*y(t-1)+0.2*epsilon

- 然后估计到一个AR(2)模型, 故意用错误的模型
- R中有非常简单的命令：arima

➢ *x2 = arima(X, order=c(2, 0, 0), method='ML')*

  - *输出：估计结果x2，输入：数据X*
  - *规定：模型设置order=c(2, 0, 0), 方法method='ML'*

```
> x2<-arima(X,order=c(2,0,0),method='ML')
> x2

Call:
arima(x = X, order = c(2, 0, 0), method = "ML")

Coefficients:
         ar1      ar2  intercept
      0.5797  -0.0408     1.9956
s.e.  0.0446   0.0447     0.0196

sigma^2 estimated as 0.04097:  log likelihood = 89.06,  aic = -170.12
>
```

- 对比估计结果与原模型，可见，这里报告的intercept不是截距项，而是均值项
- 即估计出来的模型为: y_t-1.9956 = 0.5797*(y_{t-1} -1.9956) - 0.0408*(y_{t-2} -1.9956) + ε_t
- 从t值（-0.0408/0.0447）看，AR2部分不显著
- ε_t的方差估计为0.04097 ，真实的为0.2*0.2
- 与真实过程比较，差不多。

•为了清楚地看出上面估计中intercept是均值项，我们再做一个Monte Carlo实验：

```
> X<-AR1(2,0.5,0.2,500)
> x2<-arima(X,order=c(2,0,0),method='ML')
> x2

Call:
arima(x = X, order = c(2, 0, 0), method = "ML")

Coefficients:
         ar1     ar2  intercept
      0.4767  0.0087     4.0033
s.e.  0.0447  0.0447     0.0163

sigma^2 estimated as 0.03518:  log likelihood = 127.21,  aic = -246.41
>
```

- 有时我们想估计的AR模型中的滞后项不是连续的，比如

$$y_t = \alpha + \beta_1 y_{t-1} + \beta_4 y_{t-4} + \varepsilon_t$$

- 这里不要AR的第二阶项和第三阶项，只要第一阶和第四阶项。类似的情况很多，因为有些项不显著，这样可以用一个更简单的模型。
- 上面的AR模型写成AR((1,4))，括号内的括号内分别列出AR所有的滞后项。
- 如果括号内没有括号，只有一个数字，比如AR(3)，就表示滞后项是从1开始直到那个数字(3)的所有滞后项。
- 显然前面介绍的OLS估计方法和MLE估计方法，都可以直接套用到这里。
- 下面用上述模拟数据，估计一个AR((1,4))模型，R软件中arma命令可以估计这样的模型

```
> library(tseries)
>
> arout1=arma(y, lag=list(ar=c(1,4)))
> summary(arout1)

Call:
arma(x = y, lag = list(ar = c(1, 4)))

Coefficient(s):
Estimate  Std. Error  t value Pr(>|t|)
ar1        0.49848    0.03902   12.774   <2e-16 ***
ar4       -0.01115    0.03902   -0.286    0.775
intercept  1.01473    0.10312    9.840   <2e-16 ***

Fit:
sigma^2 estimated as 0.03667,
Conditional Sum-of-Squares = 18.15,  AIC = -228.01
```

- 与“arima”命令不同，这个“arma”命令给出的 *intercept* 确实就是截距项，而不是长期均值
- 估计的模型为

$$y_t = 1.01473 + 0.49848y_{t-1} - 0.0115y_{t-4} + \varepsilon_t$$

  - 并且四阶滞后不显著

Identifying AR model (Order Selection)

- 前面估计了一个AR（2）模型。给定观察数据，如何知道该用几阶？前面用AR（2）显然不对
  - 为什么不是滞后项越多越好？反正多余项估计的无偏性（一致性）没有问题（横截面回归模型同样）。
    - 原因1：参数估计精度： $\mathrm{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\mathrm{SST}_j(1-R_j^2)}$, Rsqure_j>=0.
    - 原因2，预测精度，后面讨论
- 主要有两种模型选择方法
- **第一种是用偏自相关函数**，看偏自相关函数的变化规律，什么是偏自相关函数？
  - 估计以下AR模型组：

$$
\begin{aligned}
&\mathrm{AR}(1):\ y_t = \varphi_{1,0} + \varphi_{1,1}y_{t-1} + \varepsilon_t \\
&\mathrm{AR}(2):\ y_t = \varphi_{2,0} + \varphi_{2,1}y_{t-1} + \varphi_{2,2}y_{t-2} + \varepsilon_t \\
&\mathrm{AR}(3):\ y_t = \varphi_{3,0} + \varphi_{3,1}y_{t-1} + \varphi_{3,2}y_{t-2} + \varphi_{3,3}y_{t-3} + \varepsilon_t \\
&\cdots
\end{aligned}
$$

系列$\{\varphi_{1,1}, \varphi_{2,2}, \varphi_{3,3}, \cdots\}$即为偏自相关函数

- 偏自相关函数即控制了更近的历史时的自相关
- R中计算它的函数是pacf（datafile), 可能需要加载fBasics包

```
> pacf(x1)
> x3<-pacf(x1)
> x3

Partial autocorrelations of series 'x1', by lag

     1      2      3      4      5      6      7      8      9     10     11     12     13     14     15     16     17
 0.557 -0.041  0.017  0.019  0.009 -0.014 -0.050 -0.068  0.004 -0.006  0.003 -0.061  0.099  0.050  0.000 -0.090 -0.014
    18     19     20     21     22     23     24     25     26
 0.008  0.049 -0.015  0.031  0.009 -0.043 -0.027  0.055  0.043
> plot(x3)
```

- 画图更直观
- 对比acf，显然PACF清楚地表示AR（1）足够了

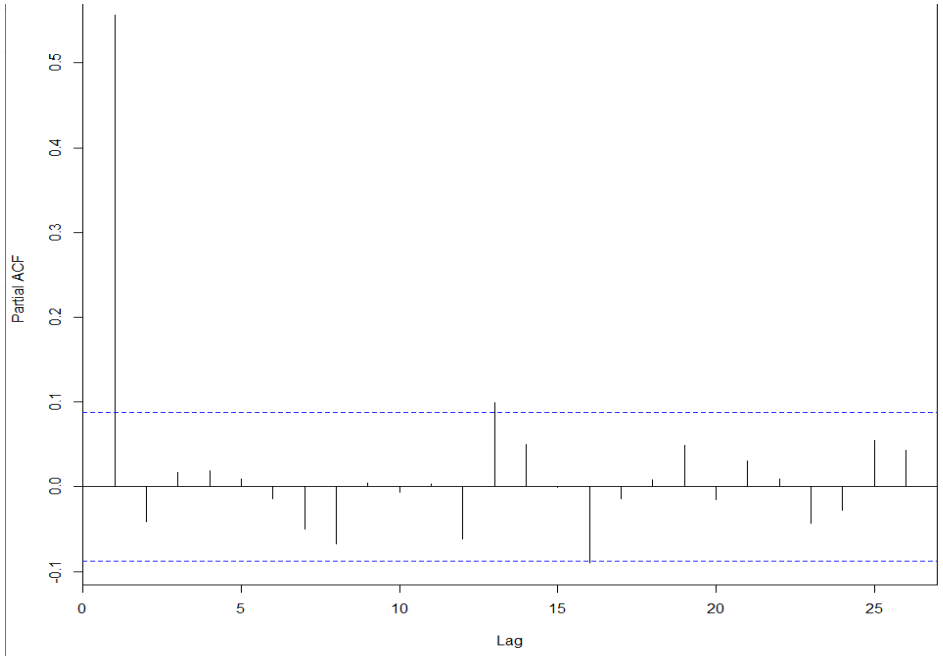

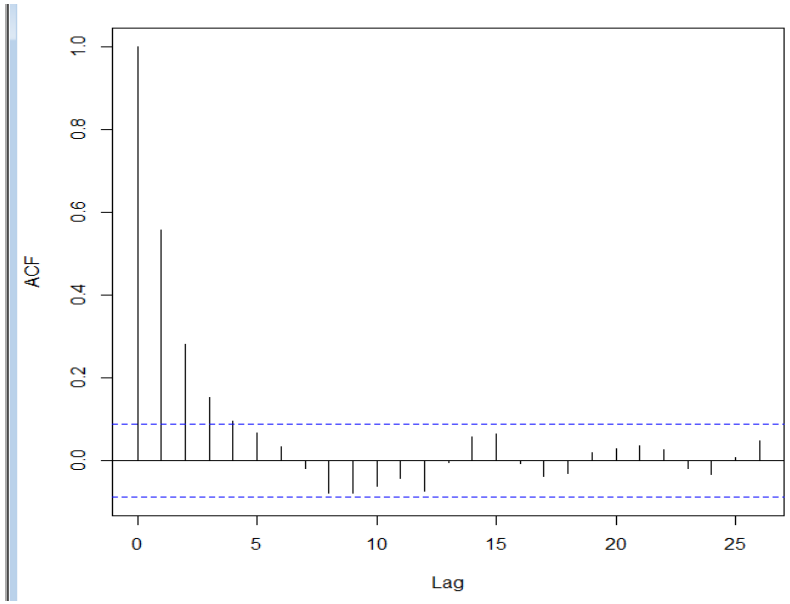

- 上面方法本质上，是用t统计量看某些项是否显著来选择。其实在经典线性模型的选择中，我们有时也用调整R2来进行模型选择：

$$\bar{R}^2 = 1 - \frac{\frac{RSS}{n-k-1}}{\frac{TSS}{n-1}} = 1 - \frac{RSS}{TSS}\frac{n-1}{n-k-1} = 1 - (1-R^2)\frac{n-1}{n-k-1}$$

  - 这里也有类似adj-R2的方法：
- Akaike information Criterion:

  AIC(p)= - 2/T {最大对数似然函数 - 模型中的参数个数}

  – 第一部分衡量了模型的拟合能力，第二部分衡量了模型的复杂度（惩罚）

  – 因此，我们的选择是AIC越小越好（定义前面有负号）
- Bayesian information criterion (or SBC):

  BIC(p)= - 2/T{最大对数似然函数 - Log(T)/2 模型中的参数个数}

  – 构成类似于AIC

  – BIC 对模型的复杂程度惩罚得更重，因此BIC比AIC偏好更小的模型
- R中的具体做法：

- 试不同的K，比较AIC，BIC

  > *p1<-arima(X,order=c(1,0,0))*
  > *p2<-arima(X,order=c(2,0,0))*
  > *p3<-arima(X,order=c(3,0,0))*
  > *p1*

- AR（1）的AIC（BIC）都比AR（2）的小，故选AR（1）
  - 选对了
- 事实上，“forecast”程序包中有一个命令“auto.arima()”可以自动做这个选择

```
> x3=auto.arima(X, ic="aic")
> summary(x3)
Series: X
ARIMA(1,0,0) with non-zero mean

Coefficients:
         ar1    mean
      0.4808  2.0033
s.e.  0.0392  0.0161

sigma^2 estimated as 0.03533:  log likelihood=127.19
AIC=-248.37   AICc=-248.32   BIC=-235.73

Training set error measures:
                       ME      RMSE       MAE        MPE     MAPE      MASE         ACF1
Training set 0.0001085995 0.1875754 0.1493244 -0.8951876 7.585222 0.8619121 -0.003203187
>
```

```
> p1=arima(X, order=c(1,0,0))
> p2=arima(X, order=c(2,0,0))
> p3=arima(X, order=c(3,0,0))
> p1

Call:
arima(x = X, order = c(1, 0, 0))

Coefficients:
         ar1  intercept
      0.4808     2.0033
s.e.  0.0392     0.0161

sigma^2 estimated as 0.03518:  log likelihood = 127.19,  aic = -248.37
> p2

Call:
arima(x = X, order = c(2, 0, 0))

Coefficients:
         ar1     ar2  intercept
      0.4767  0.0087     2.0032
s.e.  0.0447  0.0447     0.0163

sigma^2 estimated as 0.03518:  log likelihood = 127.21,  aic = -246.41
> p3

Call:
arima(x = X, order = c(3, 0, 0))

Coefficients:
         ar1      ar2     ar3  intercept
      0.4762  -0.0162  0.0521     2.0031
s.e.  0.0446   0.0495  0.0446     0.0171

sigma^2 estimated as 0.03509:  log likelihood = 127.89,  aic = -245.77
>
```

- 假如它们(AIC, BIC) 给出不同的建议，如何选择？
  - 原则1：在大样本时，BIC比AIC更准确些，而小样本时，AIC比BIC准确程度高些
    - 原因是当样本量（T）比较大时，AIC对模型复杂度(模型中的参数个数）的处罚权重=1， 太小，从而会选择过大的模型。
    - 而当T比较小时，BIC对模型复杂度的权重=log(T)/2, 过大，从而选择过小的模型。
  - 原则2：样本外预测误差比较。后面再讨论
- 后面的应用例子将详细演示如何选择模型

5. 自回归模型的应用：周期性

- 三个典型应用：预测，周期性，平稳性的判断。这里先介绍周期性
- 经济周期是宏观经济学中的核心问题之一，也是金融投资领域重点关注的问题，特别是在大类资产配置方面

- 美林时钟在2004 年由美林证券提出，理论依据是通过对几十年的各国经济发展阶段和资产青睐热度的数据，经过统计分析得出的资产配置模型
- 现在处在什么阶段？

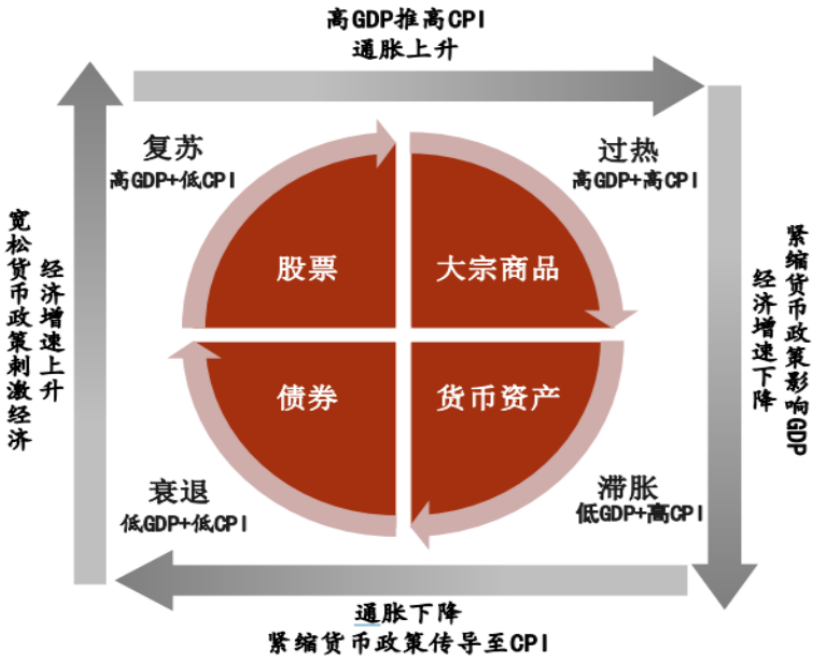

- 我们看看如何用AR模型研究中国GDP增长的周期性
- 首先读入中国1995年到2022年的季度GDP，
- 转化成R软件中的时间序列数据格式，计算同比增长率（这一期相对于去年同期的增长率）。
- 然后用偏自相关函数初选模型

```
> library(readxl)
> setwd('D:/ywang/data')
> data = read_excel('./GDP.xlsx',sheet='Sheet1')
> attach(data)
> gdp=ts(gdp,start=c(1995,4),frequency = 4)
> plot(gdp)
>
> #对数差分计算增长率
> r=diff(log(gdp), 4)
>
> #画出偏重相关系数图
> plot(pacf(r))
```

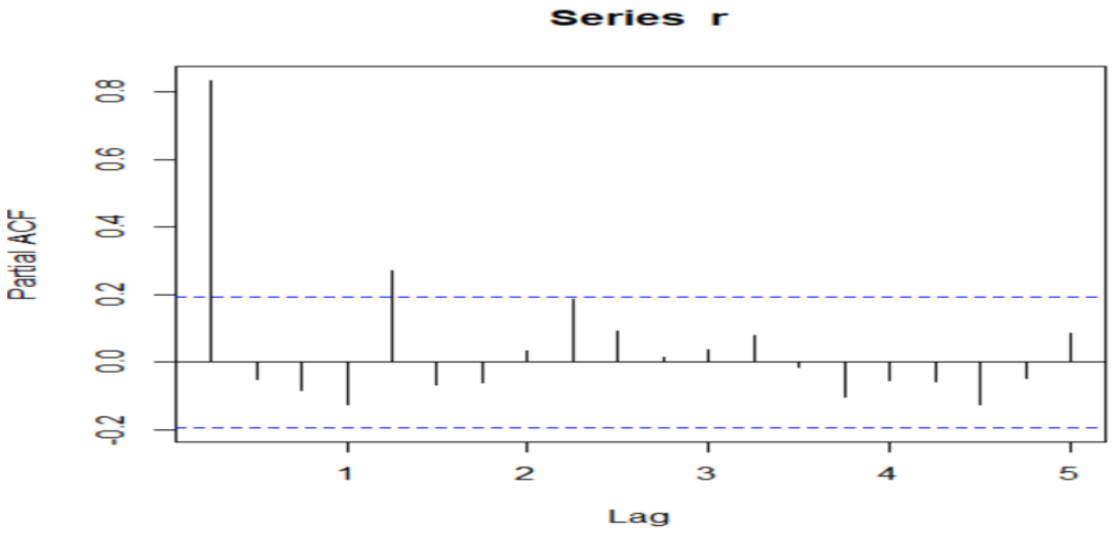

- 偏自相关函数图可以看出，模型到第五阶滞后时的偏自相关系数都非常显著，第九阶偏自相关系数也几乎显著。考虑这些元素，我们首先把AR(5)作为初选模型，再用AIC进行比较（由于样本量只有102，比较少）

- 先估计基础模型AR(5)
- 再估计备选模型AR(6),AIC差一些，六阶滞后不显著，所以AR(6)可以忽略
- AR(5)中有系数不显著，看看非连续的AR模型AR((1,4,5))， AIC更好
- 前面pacf中九阶滞后也几乎显著，故再看看AR((1,4,5,9))，AIC变差
- 最后模型选择为AR((1,4,5))
- 模型估计为

$$y_t = 0.0171 + 0.9231y_{t-1} - 0.3525y_{t-4} + 0.2764y_{t-5} + \varepsilon_t$$

表 3.1 模型选择过程

参数	AR(5)	AR(6)	AR((1,4,5))	AR((1,4,5,9))
AIC	-459.15	-456.82	-463.0	-459.16
β_1	0.8988 (9.416)***	0.9171 (9.159)***	0.9231 (14.982)***	0.9096 (14.654)***
β_2	0.0236 (0.188)	-0.0040 (-0.031)		
β_3	0.0252 (0.201)	0.0200 (0.159)		
β_4	-0.3737 (-2.962)***	-0.3748 (–2.981)***	-0.3525 (-3.295)***	-0.3474 (-3.241)***
β_5	0.2729 (2.758)**	0.3573 (2.277)**	0.2764 (2.798)***	0.2634 (2.442)**
β_6		-0.0782 (-0.650)		
β_9				0.0434 (0.640)

$$y_t = 0.0171 + 0.9231y_{t-1} - 0.3525y_{t-4} + 0.2764y_{t-5} + \varepsilon_t$$

- **计算周期长度**
  - 给定上述AR模型，特征方程为 $z^5 - 0.9231z^4 + 0.3525z - 0.2764 = 0$
  - 利用R软件中的“polyroot”命令可以求出该方程的根

```
> polyroot(c(-0.2764,0.3525,0,0,-0.9231,1))
0.5549768+0.5008818i   0.5549768-0.5008818i
-0.5285196+0.5375912i  -0.5285196-0.5375912i
0.8701856-0.0000000i
```

  - 五个根为：实数根0.8701856，和两对共轭复数根 −0.5285196±0.5375912 i ， 0.5549768±0.5008818 i
  - 共轭复数的模分别为0.75388和0.74758
  - 所有根都在单位圆内，系统平稳
  - 两对共轭复数根，意味着系统有两个周期叠加
  - 第一个周期的长度，由公式 q = 2π/θ， θ = arccos(−0.5285196/0.75388) 计算得2.6764个季度
  - 第二个周期的长度由类似公式得8.4637个季度。
  - 图形表示